UNIVERSIDAD PRIVADA DEL NORTE

BASE DE DATOS AVANZADAS Y BIG DATA

T3 — Diagnóstico de procesamiento de datos con Apache Spark

Enunciado y especificaciones para estudiantes · Semana 13 · Unidad III: Big Data · Periodo 2026-2

1. Finalidad y condiciones

Evaluación T3: desarrollo de casos (30 % del curso). Resolución por equipo y sustentación individual. Duración y fecha de exposición: según programación docente. Calificación: escala de 0 a 20 puntos.

Logro evaluado: diagnosticar y corregir un procesamiento de datos con RDD en Apache Spark, validar resultados y sustentar decisiones de arquitectura, calidad de datos, seguridad y privacidad.

2. Situación problemática

LogiFrío (organización ficticia) consolida registros de envíos de insumos con transporte refrigerado. En un sistema heredado se calculan indicadores de puntualidad por centro operativo, pero se han recibido reportes contradictorios. El equipo de ingeniería debe auditar el notebook proporcionado, corregir la lógica y documentar las decisiones. Los datos son simulados y no contienen información de personas.

3. Datos y diccionario

Archivo entregado: T3_Datos_Logistica_CadenaFrio.csv. Los campos son:

Campo	Significado
id_envio	Identificador de envío
fecha	Fecha de operación (AAAA-MM-DD)
centro	Centro operativo
ruta	Tipo de ruta
temperatura_c	Temperatura registrada en grados Celsius
meta_minutos	Meta de tiempo en minutos
tiempo_real_minutos	Tiempo de transporte registrado en minutos; puede estar vacío

4. Reglas del caso

- Temperatura aceptable para este caso didáctico: entre 2 y 8 °C, ambos límites incluidos.
- Una meta de tiempo válida debe ser estrictamente mayor que cero.
- Un registro sin tiempo real no puede contribuir al indicador de puntualidad.
- Una entrega es puntual cuando tiempo_real_minutos ≤ meta_minutos; si lo supera, presenta demora.
- Se deben identificar duplicados exactos; si aparecen duplicados no idénticos por ID, explicar cómo se resolvería la ambigüedad sin inventar una política.

- Indicador de puntualidad por centro = 100 × entregas puntuales válidas / total de entregas válidas del centro.
- Minutos acumulados de demora por centro = suma de max(0, tiempo_real_minutos − meta_minutos) de registros válidos.

5. Desafíos requeridos

- D1. Diagnóstico: documentar las inconsistencias de calidad y sus posibles efectos sobre el indicador.
- D2. Corrección: identificar errores lógicos del notebook heredado; explicar por qué son errores y corregirlos.
- D3. Implementación: obtener por centro conteo válido, puntualidad, porcentaje y minutos de demora mediante RDD y reduceByKey.
- D4. Validación: incluir al menos tres comprobaciones reproducibles y una muestra de revisión manual.
- D5. Arquitectura: describir driver, executors, particiones, paralelismo local, limitaciones frente a clúster; justificar medidas de integridad, trazabilidad y privacidad.

6. Restricciones y alcance

- Utilizar PySpark RDD como tecnología principal; no se exige Spark SQL, DataFrames avanzados ni visualización.
- Trabajar en Anaconda + JupyterLab con ejecución local; no afirmar que se ha probado un clúster multinodo.
- No modificar el archivo CSV original: si se requiere depuración, realizarla mediante RDD.
- Entregar código ejecutable; indicar las versiones de Python, Spark y el entorno utilizado.
- Puede utilizarse IA generativa como apoyo, declarando su uso y verificando cada resultado.

7. Informe académico: estructura obligatoria

- Portada: integrantes, curso, sección, docente, fecha.
- Introducción: situación, objetivo y alcance.
- Análisis del problema y de los datos: reglas, riesgos y diagnóstico.
- Diseño de la solución: estrategia RDD y justificación.
- Implementación: modificaciones significativas, con referencias a celdas del notebook.
- Validación y resultados: pruebas, tablas de indicadores y discusión.
- Arquitectura, seguridad, privacidad y limitaciones.
- Conclusiones y recomendaciones vinculadas con los resultados.
- Referencias con formato APA 7 y declaración de uso de IA, cuando corresponda.

8. Entregables y sustentación

Entregar:

1. informe académico PDF.
2. Notebook .ipynb ejecutado y con comentarios.
3. Presentación breve en PDF o PPTX.
4. Archivos auxiliares estrictamente necesarios.

En la exposición, demostrar en JupyterLab la corrección y responder preguntas individualmente.

Propuesta organizativa: 15–20 minutos por equipo; debe ajustarse al número de equipos y a la programación institucional. Cada integrante debe participar. Se valorará la coherencia entre el informe, la ejecución y la sustentación.

9. Referencias técnicas

Apache Software Foundation. (s. f.). RDD programming guide. https://spark.apache.org/docs/latest/rdd-programming-guide/

Apache Software Foundation. (s. f.). Cluster mode overview. https://spark.apache.org/docs/latest/cluster-overview.html