



BASE DE DATOS AVANZADAS Y BIG DATA

UPN.EDU.PE

Semana 07



BUSINESS INTELLIGENCE




Presentación de la sesión

Logro de sesión

Al término de la sesión los estudiantes comprenden los principios para el diseño de un Datawarehouse teniendo en cuenta las metodologías y enfoques usados, también realiza el diseño para un proceso ETL de manera lógica.

Temario

- Diseño de un datawarehouse. Modelo lógico y físico.
- Metodologías de Ralph Kimball y Bill Inmon.
- Enfoques top-down y bottom-up.
- Diseño de procesos ETL.




Datawarehouse

DATAWAREHOUSE



Es un sistema centralizado que permite a los usuarios acceder a datos históricos y actuales de diferentes fuentes y analizarlos para **tomar decisiones empresariales informadas**.


Proporciona una visión global, común e integrada de los datos de la organización, independiente de cómo se vayan a utilizar posteriormente por los consumidores o usuarios. Normalmente en el almacén de datos habrá que guardar información histórica que cubra un amplio período de tiempo.



DATAWAREHOUSE




FUENTES



WAREHOUSE

APLICACIÓN BI


OLAP





Podemos entender un Data Mart como un subconjunto de los datos del Data Warehouse con el objetivo de responder a un determinado análisis, función o necesidad y con una población de usuarios específica. Al igual que en un data warehouse, los datos están estructurados en modelos de estrella o copo de nieve y un data mart puede ser dependiente o independiente de un data warehouse.


DISEÑO DATAWAREHOUSE



ANÁLISIS DIMENSIONAL



El modelo dimensional le permite al usuario ver la data mediante múltiples dimensiones, por ejemplo ver las ventas por producto, por tienda, por mes por año. Un modelo dimensional es un modelo simple que muestra medidas, dimensiones y sus relaciones y que puede ser presentado al usuario para verificación. La información deberá ser presentada utilizando etiquetas de negocio que le sean familiares al usuario final. Este modelo puede ser utilizado para crear un esquema físico




- ✓ **Hechos** (aquello que queremos medir o analizar)
- ✓ **Dimensiones** (cómo lo queremos medir)

TABLAS DE HECHOS (FACT TABLES)




- la tabla **principal** del modelo dimensional
- contienen campos claves que se unen a las tablas de dimensión
- contiene métricas o también llamadas **medidas** y es aquello que queremos medir o analizar. Generalmente son valores numéricos que se suelen agregar
- evitan la redundancia de atributos por estas estos en las tablas de dimensiones
- normalmente tienen muchos (millones) registros
- por ejemplo: ventas, compras, movimientos de contabilidad



TABLAS DE DIMENSIÓN (DIMENSION TABLE)



- tablas simples **desnormalizadas**
- se unen a las tablas de hechos a través de un campo clave
- los atributos de la tabla de dimensión ofrecen información característica de las tablas de hechos
- no hay límite de tablas de dimensión
- las dimensiones pueden contener una o varias relaciones jerárquicas
- normalmente tiene pocos (miles) registros
- por ejemplo: clientes, productos, almacenes, proveedores, calendario..



ESQUEMA ESTRELLA Y COPO DE NIEVE






DIAGRAMA FUNCIONAL DE DIMENSIONES Y MEDIDAS



Métricas / Dimensiones	Monto Programado Plan Operativo Institucional	Monto Presupuesto Inicial Asignado	Monto Presupuesto Inicial Modificado	Monto del Devengado
Tiempo	X	X	X	X
Sector	X	X	X	X
Pliego	X	X	X	X
Ejecutora	X	X	X	X
Centro de Costo	X	X	X	X
Objetivo Estratégico	X	X	X	X
Acción Estratégica	X	X	X	X
Actividad Operativa	X	X	X	X
Programa Presupuestal	X	X	X	X
Función	X	X	X	X
Programa	X	X	X	X
Fuente de Financiamiento	X	X	X	X
Rubro	X	X	X	X
Genérica de Gasto	X	X	X	X

Matriz Bus




Matriz Star Net

DISEÑO FÍSICO



Diseño físico del almacén de datos departamental (data mart).



Modelo Estrella

METODOLOGÍAS BILL INMON



- La metodología de **Bill Inmon** se enfoca en el modelo relacional, el cual organiza los datos en una estructura de tablas normalizadas. Esta metodología se enfoca en construir un data warehouse corporativo centralizado que es consistente, completo y bien integrado. Se inicia con la identificación de las entidades empresariales y se construyen las tablas normalizadas basadas en ellas. El objetivo de esta metodología es proporcionar a los usuarios una fuente única y confiable de datos de toda la organización.




Figura 2. Data Warehouse, tipología Inmon

METODOLOGÍAS RALPH KIMBALL



- La metodología de **Ralph Kimball** se enfoca en el modelo dimensional, el cual organiza los datos en una estructura de estrella o copo de nieve. Esta metodología se enfoca en diseñar el data warehouse para responder a las necesidades específicas de los usuarios de negocios. Se inicia con la identificación de los procesos de negocios y se construyen las dimensiones y hechos basados en ellos. El objetivo de esta metodología es proporcionar a los usuarios un acceso rápido y fácil a los datos que necesitan.




Figura 3. Data Warehouse, tipología Kimball


ENFOQUES




Enfoque **Top-down**: Este enfoque comienza con una visión amplia y de alto nivel de los requerimientos de negocio. Se enfoca en la definición de los objetivos empresariales y la identificación de los procesos de negocio clave que se necesitan para alcanzar esos objetivos. A continuación, se realiza el diseño de un modelo de datos corporativo que cubre toda la organización y se utiliza como base para diseñar y construir los data marts específicos de cada área funcional.

Enfoque **Bottom-up**: Este enfoque comienza con la construcción de los data marts específicos de cada área funcional. Cada data mart se construye de manera independiente, y luego se integran para formar un data warehouse corporativo.

1. Top-down approach:




2. Bottom-up approach:




ENFOQUES



Enfoque **Top-down**: Este enfoque se centra en la creación de un data warehouse corporativo que sirve a todas las áreas funcionales de la organización. Es decir, el diseño y la construcción comienzan desde arriba (visión general) y van hacia abajo (detalles específicos).



Enfoque **Bottom-up**: Este enfoque se centra en la creación de data marts específicos de negocio que abordan necesidades específicas de los usuarios y que se integran posteriormente en un data warehouse corporativo. Es decir, el diseño y la construcción comienzan desde abajo (necesidades específicas) y van hacia arriba (visión general).





Diseño proceso ETL




The ETL Process Explained



Extract

Retrieves and verifies data
from various sources



Transform

Processes and organizes
extracted data so it is usable



Load

Moves transformed data
to a data repository



ETL Nunca Ha Sido Fácil

InformationWeek Reports, 2012 BI and Information Management Trends

Cual son los mayores impedimentos para el éxito del manejo de información en su empresa?

- 59% Acceso a información confiable
- 46% Integración de datos (ETL)
- 41% Saneamiento y de-duplicación de datos

The ETL Data Warehouse toolkit, 2004. Joe Caserta / Ralph Kimball

70% a 80% del presupuesto y tiempo en proyectos de Data Warehouse lo consume el ETL

"ETL hace o deshace el Data Warehouse"



Requerimientos

Funcional

Contenido, información

Regulatorios

Regulaciones legales

Calidad de información

"Aptitud para su uso"

Seguridad

Backups, datos en transito, staging, código, etc.

Archivado, retención y linaje

Transparencia, auditoría, monitoreo

Interfaces de consumo


"Aptitud para su uso"

Habilidades técnicas disponibles

A veces la mejor herramienta es aquella que sabemos como usar



ETL Requiere Arquitectura





¿Que ha cambiado desde la ultima ejecución?

Procese solo registros nuevos o cambiados es mas eficiente

Extraer Vs. Recibir

Mecanismos consistentes como publicar-subscribir tiende a reducir complejidad y aumenta estabilidad del sistema ETL

¿Almacenar o no almacenar?

Archivos planos son simples y fácil de implementar



Transformar

Limpiar

De-duplicar

Manejo de Excepciones

Otras transformaciones

¿Cómo se van a ensamblar los registros?

Ej. Vienen de diferentes sistemas? A diferentes intervalos?

¿Tenemos claras la reglas de de-duplicación?

Mecanismos consistentes tipo publicar-subscribir tiende a reducir complejidad y aumenta estabilidad del sistema ETL

¿Cómo se evalúan y procesan registros defectuosos?

Detección, manejo y auditoria son siempre necesarios

Otras transformaciones

Generación de PKs, Conversiones , etc, etc, etc



Cargar

Agregar

Cargar

Post-Procesos

Entender estructuras de datos en el destino y sus dependencias

Es importante que el ETL entregue los datos en un formato y manera fácil y amigable

Rutinas post-proceso

e.g. reconstruir índices, procesar cubos, calentar memoria, etc



Operatividad, Instrumentación

Horario Ejecución

Monitor de Actividad

Backup

Re-Ejecuciones

Notificaciones

Auditoria

Seguridad

Regulatorio

¿Proceso termino correctamente?

¿Podemos monitorear el proceso?

¿Tengo suficientes detalles en caso de un error de ejecución?

¿Tengo suficiente información para auditoria o resolver problemas?

¿En caso de un error, puede el proceso re-iniciarse sin mayor intervención?



¿Podemos garantizar la seguridad del código fuente, y los datos en transito y en disco?

¿Puedo dormir tranquilo por las noches?

HERRAMIENTAS



La



HERRAMIENTAS ETL





¿Preguntas o comentarios?



CONCLUSIONES

El Datawarehouse permite tomar decisiones de manera informada. Existen las metodologías **Bill Inmon** y **Ralph Kimball**. También podemos considerar el enfoque a usar **Top-down** o **Bottom-up**

El modelo dimensional esta compuesto por tablas de Hechos, que es lo que queremos medir o analizar y Tablas de Dimensiones, que es cómo lo queremos medir.

El ETL, corresponde a los procesos de Extracción, Transformación y Carga (Load).



REFERENCIAS BIBLIOGRÁFICAS



Bigdata vs BI

<https://www.ippbsolutions.com/solucion-big-data-vs-business-intelligence-data-warehousebig-data-vs-inteligencia-de-negocios/>

Comparando Herramientas ETL


<https://aprenderbigdata.com/herramientas-etl/>

Extracción, transformación y carga de datos (ETL)

<https://learn.microsoft.com/es-es/azure/architecture/data-guide/relational-data/etl>

Tutorial de SSIS: Crear un paquete ETL sencillo

<https://learn.microsoft.com/es-es/sql/integration-services/ssis-how-to-create-an-etl-package?view=sql-server-ver16>



GRACIAS

