

Proyecto SQL / Limpieza de Datos - LearnData

Creado por	Ⓜ Marcela Juarez
Fecha de creación	@15 de noviembre de 2023 21:23

📋Descripción del Proyecto

El proyecto de limpieza de datos con SQL tiene como objetivo principal mejorar la calidad y confiabilidad de los conjuntos de datos utilizados en las organizaciones. Los datos desempeñan un papel fundamental en la toma de decisiones y la generación de informes, por lo que es esencial garantizar que estén libres de errores, inconsistencias y duplicados.

🎯El objetivo de este proyecto

- Creación de una base de datos.
- Identificar y corregir inconsistencias.
- Detección y eliminación de duplicados.
- Normalización de datos.

📝Contexto

LearnData es una empresa de e-learning dedicada a la venta de cursos online de análisis de datos. Su principal objetivo es:

- Comenzar a construir una infraestructura tecnológica para analizar sus datos.
- Limpiar los datos para que los puedan consumir las áreas de negocio.

Utiliza las siguientes herramientas para gestionar su negocio:

- **Stripe**: Es una plataforma de procesamiento de pagos por internet, al igual que paypal.
- **Wocommerce**: Es un plugin de wordpress que te permite convertir tu web a un sitio de ecommerce y vender productos.
- **Wordpress:** Es un sistema de gestión de contenidos(CMS), un software utilizado para construir, modificar y mantener sitios web.

🆘 El problema

LearnData ha ido creciendo en la venta de sus cursos online y no tiene información de cuáles son sus indicadores de ventas, por lo cual requiere comenzar a analizar sus principales métricas financieras, para determinar qué productos tienen mayor venta, qué tipo de clientes compran sus productos o cuáles son los pagos que reciben por producto.

En este momento LearnData no tiene ningun sistema creado para poder capturar, analizar y tomar mejores decisiones y necesita tener una base de datos donde puedan ver y analizar esta información y a futuro crear un dashboard con los KPI para ver el rendimiento de su negocio de cursos online.

🛠️Herramientas a utilizar

En este proyecto utilizaremos lenguaje de SQL y el gestor de base de datos MYSQL.

📶Conjunto de datos del proyecto

👩‍💻Tabla raw_cliente_wocommerce:

Contiene información sobre los clientes.

Nombre Tabla	Nombre Campo	Descripción
raw_cliente_wocommerce	id	Identificador del Cliente
raw_cliente_wocommerce	links	Página donde se creo el cliente
raw_cliente_wocommerce	billing	Datos de Facturación
raw_cliente_wocommerce	last_name	Apellido del Cliente
raw_cliente_wocommerce	phone	Número de Télefono del Cliente
raw_cliente_wocommerce	postcode	Código postal
raw_cliente_wocommerce	date_created	Fecha de Creación
raw_cliente_wocommerce	meta_data	Data del postal web
raw_cliente_wocommerce	role	Rol del cliente

📦Tabla raw_pedidos_wocommerce

Contiene información de los pedidos.

Nombre Tabla	Nombre Campo	Descripción
raw_pedidos_wocommerce	numero_de_pedido	Número del Pedido
raw_pedidos_wocommerce	estado_de_pedido	Estado del Pedido
raw_pedidos_wocommerce	fecha_de_pedido	Fecha del Pedido
raw_pedidos_wocommerce	id cliente	Identificador del Cliente
raw_pedidos_wocommerce	titulo_metodo_de_pago	Metodo de Pago
raw_pedidos_wocommerce	importe_de_descuento_del_carrito	Descuentos
raw_pedidos_wocommerce	importe_subtotal_carrito	Monto Subtotal
raw_pedidos_wocommerce	importe_envio_pedido	Monto Envio
raw_pedidos_wocommerce	importe_reembolsado_pedido	Monto Reembolso
raw_pedidos_wocommerce	importe_total_pedido	Monto Total del Pedido
raw_pedidos_wocommerce	importe_total_de_impuestos_del_pedido	Monto Total de Impuestos
raw_pedidos_wocommerce	sku	Código del producto
raw_pedidos_wocommerce	articulo_numero	Número del Artículo
raw_pedidos_wocommerce	nombre_del_articulo	Nombre del Artículo
raw_pedidos_wocommerce	cantidad	Cantidad
raw_pedidos_wocommerce	coste_articulo	Precio del Artículo
raw_pedidos_wocommerce	cupon_articulo	Cupón
raw_pedidos_wocommerce	importe_descuento	Monto de Descuento
raw_pedidos_wocommerce	importe_impuestos_descuento	Monto Impuesto

📚Tabla raw_productos_wocommerce

Contiene información sobre los productos.

Nombre Tabla	Nombre Campo	Descripción
raw_productos_wocommerce	id	Identificador del Producto
raw_productos_wocommerce	tipo	Tipo de Producto
raw_productos_wocommerce	sku	Código del Producto
raw_productos_wocommerce	nombre	Nombre del Producto
raw_productos_wocommerce	publicado	Indicador de Publicidad
raw_productos_wocommerce	visibilidad_catalogo	Visibilidad de Catálogo
raw_productos_wocommerce	descripcion_corta	Descripción de Producto
raw_productos_wocommerce	estado_impuesto	Impuesto
raw_productos_wocommerce	clase_impuesto	Tasa de Impuesto
raw_productos_wocommerce	en_inventario	Indicador del Inventario
raw_productos_wocommerce	Inventario	Tipo de Inventario
raw_productos_wocommerce	cantidad_de_bajo_inventario	Cantidad de Inventario
raw_productos_wocommerce	vendido_individualmente	Indicador de Venta
raw_productos_wocommerce	peso_kg	Peso del producto
raw_productos_wocommerce	longitud_cm	Longitud del Producto
raw_productos_wocommerce	anchura_cm	Ancho del Producto
raw_productos_wocommerce	altura_cm	Altura del Producto
raw_productos_wocommerce	precio_normal	Precio Normal del Prodcuto
raw_productos_wocommerce	categorias	Categoría

💰Tabla raw_pagos_stripe

Contiene información sobre los pagos.

Nombre Tabla	Nombre Campo	Descripción
raw_pagos_stripe	id	Identificador del Pago
raw_pagos_stripe	amount	Cantidad
raw_pagos_stripe	created	Fecha de Creación
raw_pagos_stripe	currency	Moneda
raw_pagos_stripe	description	Descripción del Producto
raw_pagos_stripe	fee	Tarifa
raw_pagos_stripe	net	Pago Neto
raw_pagos_stripe	source	Fuente
raw_pagos_stripe	status	Estado del Pago
raw_pagos_stripe	type	Tipo de Pago

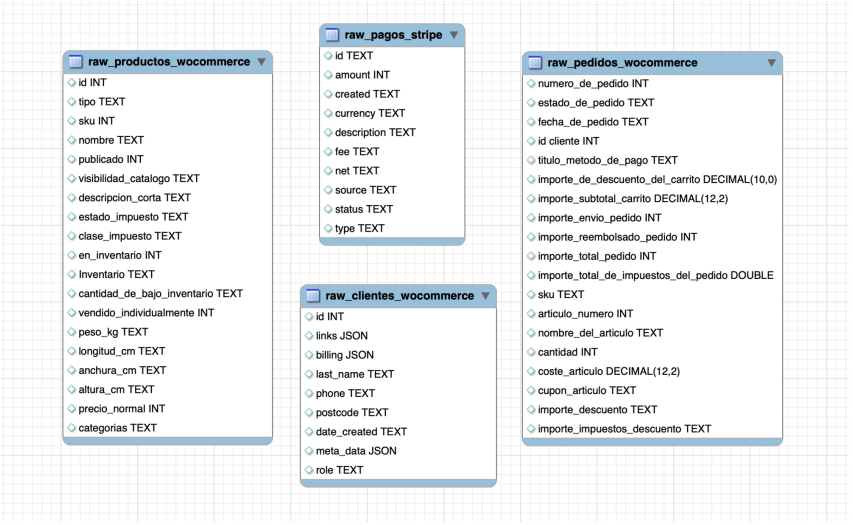
Los datos

🧮 Datos en Csv

🗃️ Base de datos .sql

↔ Modelo de Datos

En la siguiente imagen se muestran los campos de cada tabla con su tipo de dato con el cual se podrá hacer el análisis de sus relaciones.



💡Desarrollo | Ejecución

1 Paso: Análisis previo del problema

1. ¿Qué fuentes de datos tiene la empresa?
    - La empresa utiliza Wordpress con un plugin de Wocommerce como plataforma de venta de sus cursos online y, luego, cuenta con Stripe como pasarela de pagos además de los pagos con tarjeta de crédito.
2. ¿En qué formato se descargan los datos?
    - Los datos crudos los tendremos en csv directamente descargados de las fuentes.
3. ¿Qué datos tenemos?
    - Tenemos datos de los productos, o sea, cursos que se venden, los clientes, los pedidos y los pagos recibidos por stripe.
4. Modelo de datos
    - Tenemos la tabla de pedidos que se relaciona con la de clientes y productos mediante SKU_producto e id_cliente y, por otro lado, tenemos la tabla la de pagos de Stripe que la relacionaremos con la de pedidos por el número de pedido.
5. Análisis exploratorio de las tablas.

2 Paso: ✍️Ejecución

Parte I - Limpieza de datos en tablas crudas

1. Verificar que no existan campos nulos, de existir reemplazar por cero(0).
2. Cambiar el formato de las fechas por formato tipo date (D-MM-YYYY).
3. Verificar que no existan caracteres extraños en los campos de nombre del cliente, descripción del producto, dirección, de existir cambiarlo a un caracter alfanumérico.
4. Verificar que los tipos de datos de los campos ID son de tipo entero (int) en las tablas.
5. Verificar si existen datos duplicados, de existir crear una tabla de respaldo y pasarlos a esa tabla para ser analizados.

Parte II - Creación de una nueva base de datos para almacenar las tablas + tablas

1. Crear una nueva base de datos en MYSQL llamada **“learndata”.**

> 💡 Create a new schema in the connected server

2. Crear la tabla de productos llamada **dim_producto** a partir de los datos en crudo.

a. Chequear como vienen los datos.

b. Cambiar los nombres de los campos.

c. Insertar los campos a la nueva tabla.

```
CREATE TABLE learndata.dim_producto(
id_producto int,
sku_producto int,
nombre_producto varchar(100),
publicado_producto boolean,
inventario_producto boolean,
precio_normal_producto decimal(12,2),
categoria_producto varchar(100),
PRIMARY KEY (sku_producto)
)
```

```
INSERT INTO dim_producto
SELECT
id as id_producto,
sku as sku_producto,
nombre as nombre_producto,
publicado as publicado_producto,
en_inventario as inventario_producto,
CAST(precio_normal as decimal (12,2)) as  precio_normal_producto,
categorias as categoria_producto
FROM learndata_crudo.raw_productos_wocommerce;
```

- En esta tabla, sólo se modificó el datatype para pasar de un interger a un decimal para la columna **precio_normal_producto**.

2. Crear la tabla de clientes llamada **dim_clientes** a partir de los datos en crudo.
   a. Chequear como vienen los datos.
   b. Cambiar los nombres de los campos.

```
CREATE TABLE learndata.dim_clientes(
id_cliente int,
fecha_creacion_cliente date,
nombre_cliente varchar(100),
apellido_cliente varchar(100),
email__cliente varchar(100),
telefono_cliente varchar(100),
pais_cliente varchar(100),
codigo_postal_cliente varchar(100),
direccion_cliente varchar(100),
PRIMARY KEY (id_cliente)
)
```

   c. Convertir el campo date_created que viene como timestamp a solo fecha.

   d. Extraer del campo billing, todos los descriptivos del cliente que necesitamos aprendiendo a parsear un JSON.

e. Insertar los campos a la nueva tabla.

```
INSERT INTO dim_clientes
SELECT
id as id_cliente,
DATE(str_to_date(date_created,"%d/%m/%Y %H:%i:%s")) as fecha_creacion_cliente,
JSON_VALUE(billing,'$[0].first_name') AS nombre_cliente,
JSON_VALUE(billing,'$[0].last_name') AS apellido_cliente,
JSON_VALUE(billing,'$[0].email') AS email_cliente,
JSON_VALUE(billing,'$[0].phone') AS telefono_cliente,
JSON_VALUE(billing,'$[0].Region') AS region_cliente,
JSON_VALUE(billing,'$[0].country') AS pais_cliente,
JSON_VALUE(billing,'$[0].postcode') AS codigo_postal_cliente,
JSON_VALUE(billing,'$[0].address_1') AS direccion_cliente
FROM learndata_crudo.raw_clientes_wocommerce;
```

- Se tomó de la columna **billing** de la tabla de origen, usando la función JSON, los datos correspondientes para lograr obtener una tabla de **dim_clientes** limpia y ordenada.

3. Crear la tabla de pedidos llamada **fac_pedidos** a partir de los datos en crudo.

```
CREATE TABLE learndata.fac_pedidos(
id_pedido int,
sku_producto int,
estado_pedido varchar(50),
fecha_pedido date,
id_cliente int,
tipo_pago_pedido varchar(50),
costo_pedido decimal(12,2),
importe_descuento_pedido decimal(12,2),
importe_total_pedido decimal(12,2),
cantidad_pedido int,
codigo_cupon_pedido varchar(100),
PRIMARY KEY (id_pedido),
FOREIGN KEY (id_cliente) references dim_clientes(id_cliente),
FOREIGN KEY (sku_producto) references dim_producto(sku_producto)
)
```

1. Cambiar los nombres de los campos
2. Chequear como vienen los datos
3. Sustituir el nombre del producto por el id.
4. Normalizar la columna método de pago.
5. Convertir a date la columna fecha_pedido.
6. Redondear decimales de la columna coste_articulo a enteros.
7. Insertamos los pedidos a la tabla.

```
INSERT INTO fac_pedidos
SELECT
```

```
numero_de_pedido as id_pedido,
CASE WHEN p.sku_producto is null then 3 else p.sku_producto end as sku_producto,
estado_de_pedido as estado_pedido,
DATE(fecha_de_pedido) as fecha_pedido,
`id cliente` as id_cliente,
CASE WHEN titulo_metodo_de_pago LIKE '%Stripe%' then 'Stripe' ELSE 'Tarjeta' END as tipo_pago_pedido,
coste_articulo as costo_pedido,
CAST(importe_de_descuento_del_carrito AS DECIMAL(12,2)) as importe_descuento_pedido,
CAST(importe_total_pedido AS DECIMAL (12,2)) as importe_total_pedido,
cantidad as cantidad_pedido,
cupon_articulo as codigo_cupon_pedido
FROM learndata_crudo.raw_pedidos_wocommerce pe
LEFT JOIN learndata.dim_producto p on p.nombre_producto = pe.nombre_del_articuloS
```

- Con la función CASE WHEN se logra convertir los valores nulos de la columna sku en valores asignados para ese campo.
- Se formatea la columna fecha_pedido con la función DATE.
- Se modifica el título de la columna “id cliente” por id_cliente.
- Se utiliza la función CASE WHEN para extraer de la columna titulo_metodo_de_pago, una columna limpia en donde se visualice claramente el tipo_pago_pedido correspondiente.
- Se utiliza la función CAST para pasar de un valor en formato “integer” a un valor en formato “decimal” en la columna importe_total_pedido.

4. Crear la tabla de cobros de stripe llamada **fac_pagos** a partir de los datos en crudo.

```
CREATE TABLE learndata.fac_pagos(
id_pago varchar(50),
fecha_pago datetime(6),
id_pedido int,
importe_pago int,
moneda_pago varchar(5),
comision_pago decimal(12,2),
neto_pago decimal(12,2),
tipo_pago varchar(50),
PRIMARY KEY (id_pago),
FOREIGN KEY (id_pedido) references fac_pedidos(id_pedido)
)
```

    1. Chequear como vienen los datos.
    2. Cambiar los nombres de los campos.
    3. Obtener el número de pedido con la función RIGHT. Quitar el número de pedido de la descripción que es lo que nos va a permitir unir esta tabla con otras.
    4. Pasar a timestamp el campo “created”.
    5. Reemplazar las comas por puntos.

6. Convertir el número a decimal con dos lugares después de la coma.
7. Insertar tabla nueva.

> 💡 Como MySQL no toma TIMESTAMP como un formato, utilizamos “SET @@SESSION.sql_mode='ALLOW_INVALID_DATES';” para poder insertar la tabla.

```
SET @@SESSION.sql_mode='ALLOW_INVALID_DATES';
```

```
INSERT INTO fac_pagos
SELECT
id as id_pago,
TIMESTAMP(created) as fecha_pago,
RIGHT(description, 5) as id_pedido,
ABS(CAST(amount as DECIMAL (12,2))) as importe_pedido,
currency as moneda_pago,
CAST(REPLACE(fee,',','.') as DECIMAL(12,2)) as comision_pago,
ABS(CAST(REPLACE(net,',','.') as DECIMAL(10,2))) as neto_pago,
type as tipo_pago
FROM learndata_crudo.raw_pagos_stripe;
```

- Para cambiar el formato de fecha - hora a uno coherente, se utiliza la función TIMESTAMP.
- Se recurre a la función RIGHT para obtener los 5 dígitos de **id_pedido**, ya que, nos permite extraer esos 5 caracteres del lado derecho de la columna **description**.
- Se modifica la columna **amount** que contiene “texto” con la función CAST para obtener una columna final de **importe_pedido** en formato “decimal”. Así, como también, sucede con la columna **fee** y, con la columna **net,** en la tabla de origen**.**

> 💡 Primer paso: REPLACE(fee, ',','.') as paso1,
> Código utilizado en la columna de comision_pago para pasar de coma a punto, ya que, SQL interpreta la separación de decimales con un punto.

CONCLUSIÓN:

Es evidente que como analistas de datos se debe tener especial énfasis en analizar detenidamente el tipo de datos con el que contamos y con el que debemos trabajar. Aunque, igual de importante es contar con un equipo de trabajo con el que podamos tener una comunicación fluida y asertiva y que, de igual modo, pueda resolver dudas y cuestiones relativas a la carga de datos. Así como, es de fundamental importancia conocer al cliente o,

mejor dicho, el “tipo de negocio”, sumergirnos en su lenguaje, saber con qué parámetros se registran los datos, recolectar toda la información necesaria para, de esta manera, tener una capacidad de análisis acorde y coherente con el tipo de negocio.

Queda claro que a partir de realizar un análisis a fondo de los datos, tablas, llevar a cabo formateos, eliminar datos, crear una nueva base de datos y crear nuevas tablas, se sobreentiende el porqué los analistas de datos pasamos gran parte de nuestro tiempo en esta área.

También me gustaría destacar algunos detalles que he entendido en el proceso:

- Como lo mencionado anteriormente, debemos pasar tiempo estudiando el tipo de negocio, así lograremos beneficiarnos de ese conocimiento adquirido a la hora de enfrentarnos a los datos que leemos en las tablas. A veces, los datos pueden resultar confusos o hasta incomprensibles si no tenemos idea del tipo de negocio que estamos analizando.
- Cuando no conocemos el tipo de función que se debe utilizar para transformar datos podemos buscarla, pues, no lo sabemos todo. No traemos incorporado el diccionario SQL.
- Ser pacientes cuando no nos resultan las queryes. Cuestionarse el procedimiento para saber identificar el problema.
- No siempre lo que le resulta a uno, puede resultarle a otro. Pueden existir varias formas de llegar a un mismo resultado.
- Se debe comprender lo que tenemos para llegar a lo que queremos. Estudiar detenidamente la información, comprenderla, hacer una “lista de pasos” para evitar la confusión y, llevar un registro de las queryes ejecutadas, lo cual, puede resultar como medida de salvataje si tenemos inconvenientes en el camino (cosa que sucede normalmente).

Como analistas de datos sabemos que no solo se nos pide analizar datos y obtener un informe detallado de ello, también sabemos que el 80% del tiempo de nuestro trabajo se tratará de reordenar, formatear, modificar y/o reconstruir una nueva base de datos que cumpla con las necesidades de negocio y que la información allí encontrada se pueda visualizar de forma limpia y clara, de esta manera no sólo se cumple con el objetivo del trabajo, sino, que además, se lleva a cabo un procedimiento que nos permite optimizar el almacenamiento de datos de nuestro cliente para que perdure en el tiempo.