

# BASE DE DATOS AVANZADAS Y BIG DATA

UPN.EDU.PE

# Semana 09

Arquitectura de Datos y Big Data

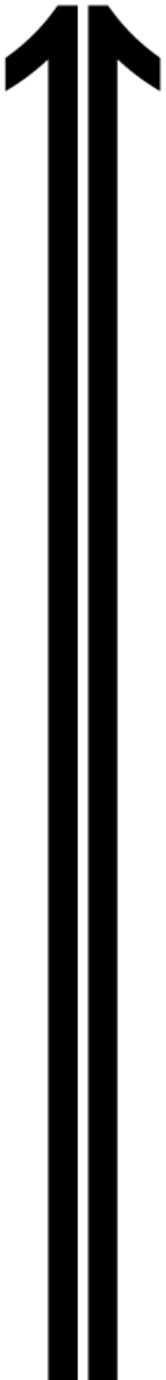
# Presentación de la sesión

## Logro de sesión

Al término de la sesión los estudiantes comprenden cómo se integran los componentes de una arquitectura de datos en un entorno de Big Data manteniendo la seguridad.

## Temario

- Arquitectura de datos.
- Integración de datos. Big data y analítica. Componentes.
- Arquitectura Metadatos.
- Seguridad y privacidad



Bigdata

# QUÉ ES BIGDATA?

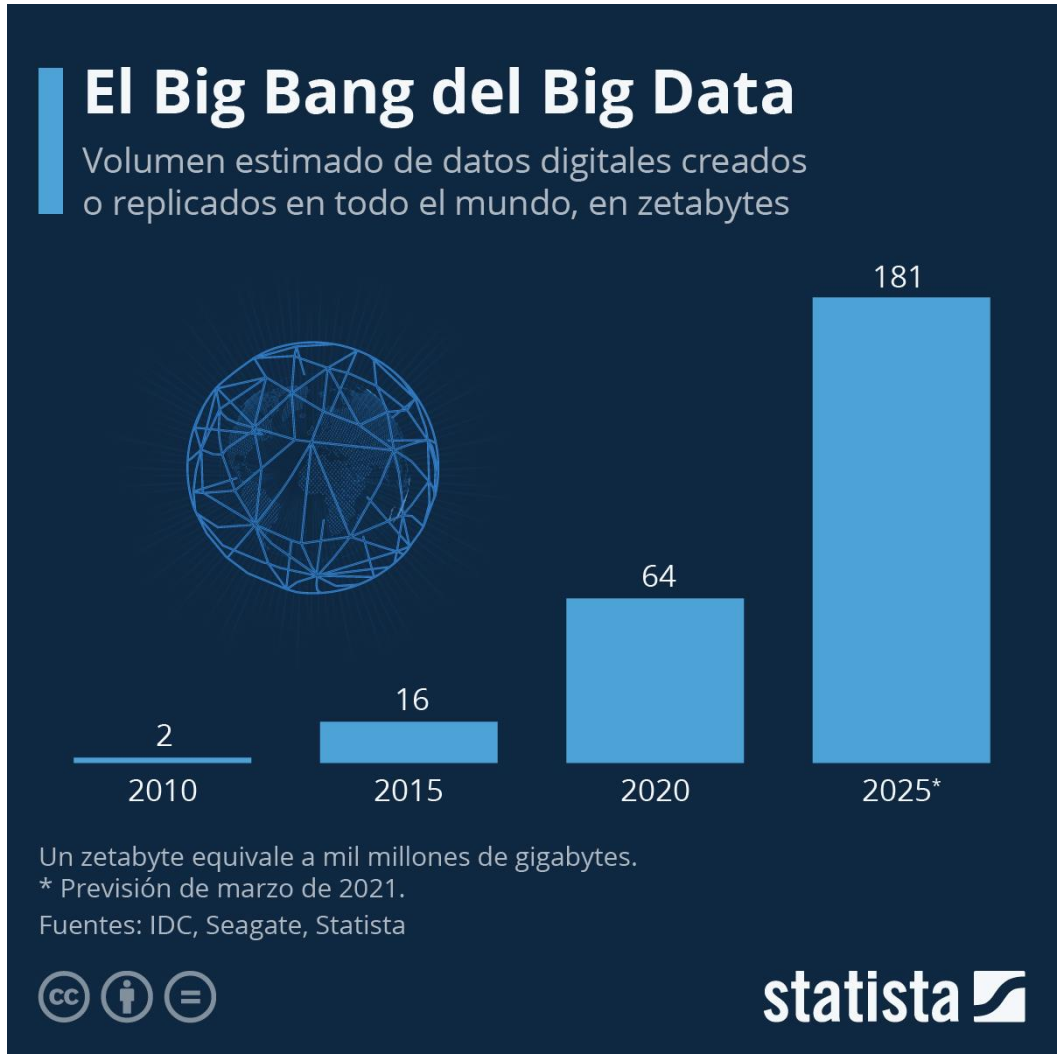
El término “big data” abarca datos que contienen una mayor variedad y que se presentan en volúmenes crecientes y a una velocidad superior. Esto también se conoce como “las tres V”.



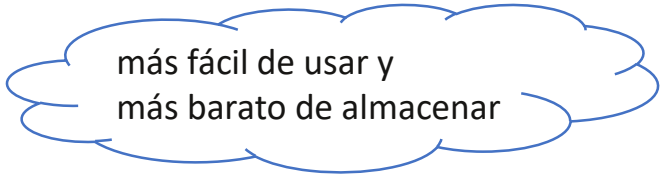

Aunque el significado de **Big Data** parece simple de comprender, este concepto encierra una alta complejidad por el contexto. No estamos hablando solo de una acumulación de datos, sino de la **generación de valor a partir de su procesamiento y análisis en tiempo real**. En ese sentido, las distintas tecnologías están en constante evolución para perfeccionar la **eficiencia operativa**, detectar los **insights ocultos**, conectarse con el mercado y **predecir sus patrones** de comportamiento para tomar de decisiones debe convertirse en nueva forma de gestionar los negocios.

# QUÉ ES BIGDATA?

El 90% de los datos de todo el mundo se han creado en los últimos dos años. El 80% de los datos mundiales son no estructurados, es decir, no están en bases de datos al uso. Solo el 20% de todos los datos está disponible para sistemas tradicionales.



# QUÉ ES BIGDATA?




Hadoop

Hadoop (SPARK)

Cloud Computing

aprendizaje automático

NoSQL

**1960 y 1970**
1ros centros de datos
BD Relacional

**2005**
+ Datos
Facebook, Youtube
Otros servicios

+ Datos

Internet de las cosas (IoT)

# CASOS DE USO BIGDATA



| Desarrollo de productos | Mantenimiento predictivo | Experiencia del cliente | Fraude y conformidad | Aprendizaje automático (ML) | Eficiencia operativa | Impulse la innovación |
|---|---|---|---|---|---|---|
| • Neflix<br>• P&G | • fallos mecánicos<br>• Rentable<br>• Tiempo Servicio | • Redes sociales<br>• Llamadas<br>• Visitas Web | • Evoluciona<br>• Patrones de Fraude | • GPT | • Toma de decisiones en función de la demanda de mercado | • Decisiones financieras<br>• Consideraciones de planificación |

# HADOOP

## Que es Hadoop



# ARQUITECTURA DE DATOS



## *Apache Hadoop*

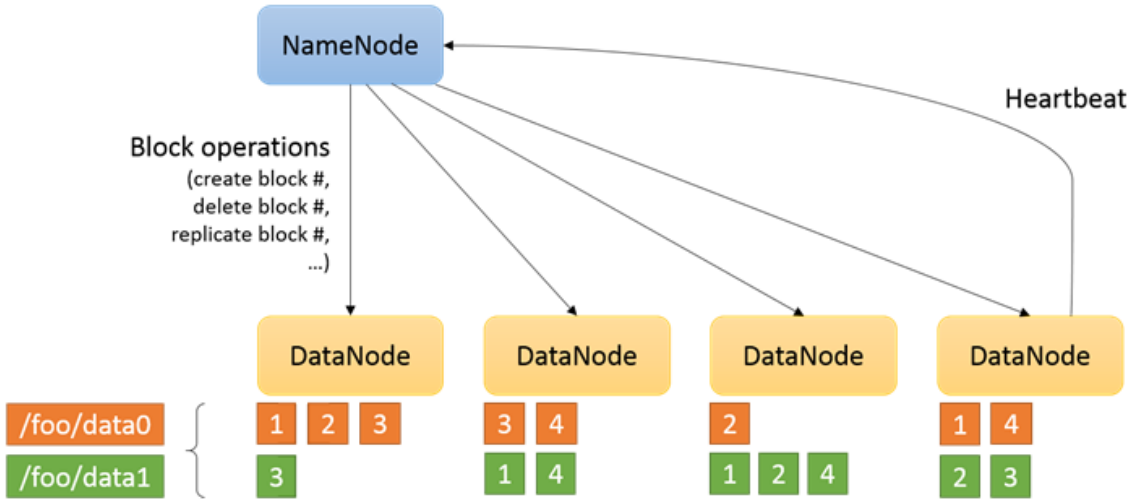
- *Es un framework basado en  Hardware y Software para  el procesamiento distribuido*
- *Apache Hadoop es un proyecto completo en OpenSource.*

Hadoop nace para enfrentar retos de disponibilidad, performance, costos así como gestión de datos y se conforma de algunos componentes importantes:

- *Hadoop Common:* Las utilidades comunes que soportan los otros módulos de Hadoop, integración, scheduler, shell, codigo nativo, jars, Python.
- *Hadoop Distributed File System (HDFS) :* Un sistema de archivos distribuido que proporciona acceso de alto rendimiento para los datos de aplicación.
- *Hadoop YARN*: Un marco para la planificación de tareas y gestión de recursos de clúster.
- *Hadoop MapReduce:* Un sistema basado en hilos para el procesamiento paralelo de grandes conjuntos de datos.

# HADOOP HDFS

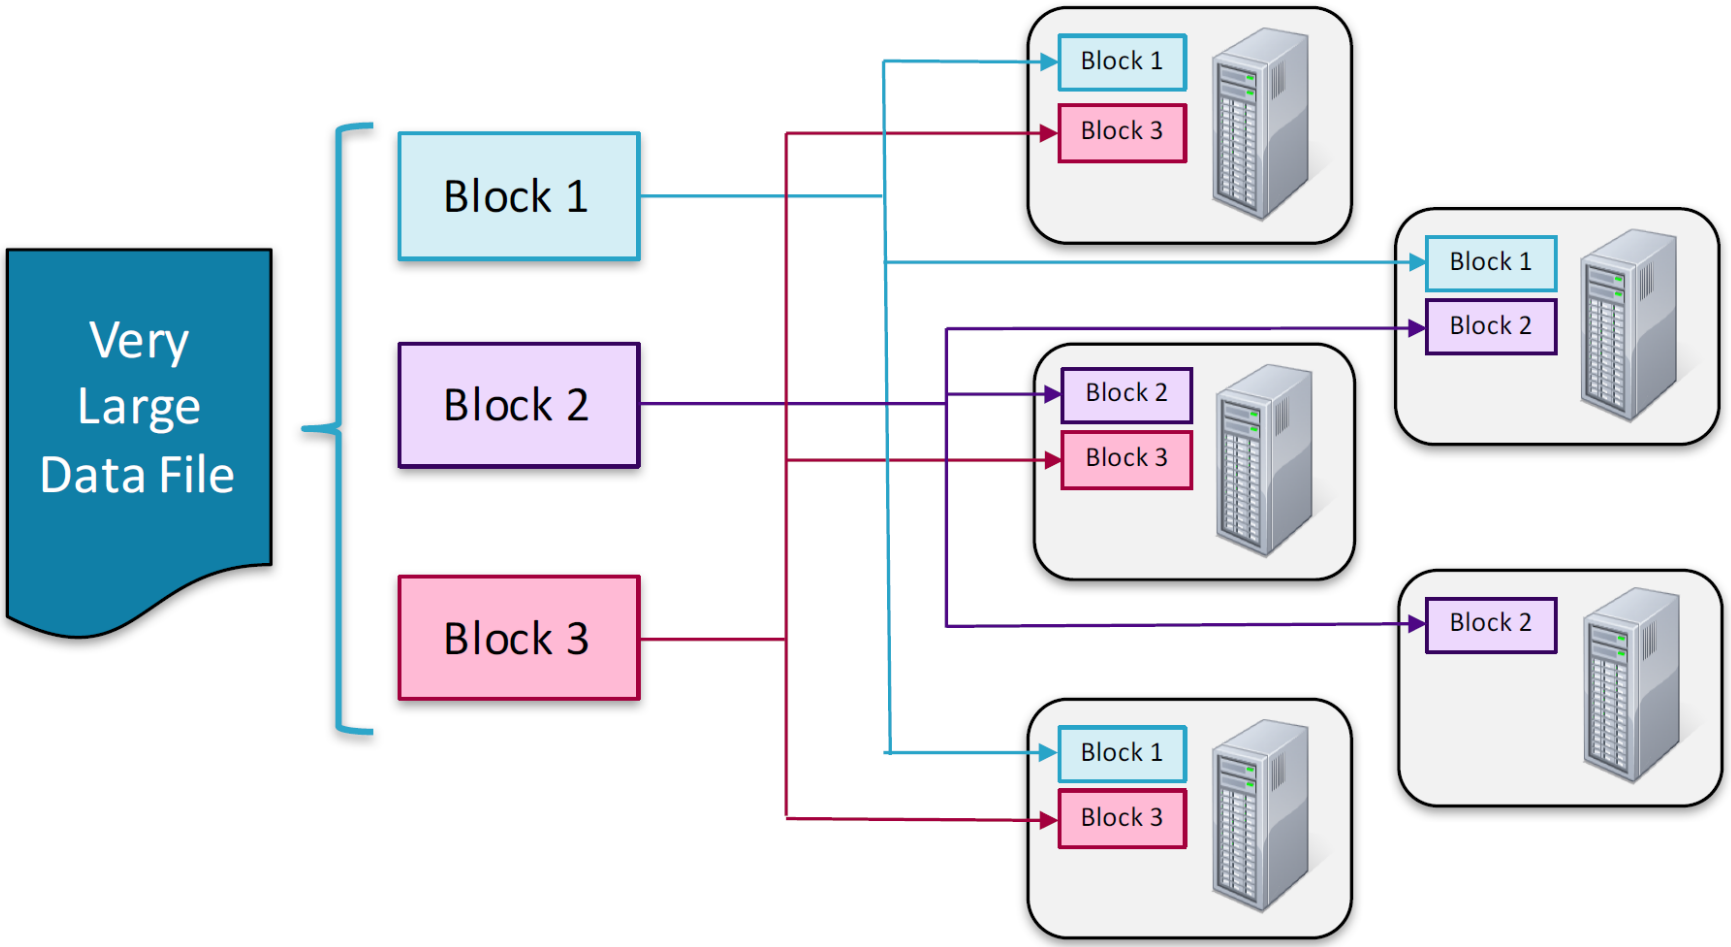
***HDFS:*** El Hadoop Distributed File System (HDFS) es un sistema de archivos distribuido diseñado para ejecutarse en hardware agrupado(grid).



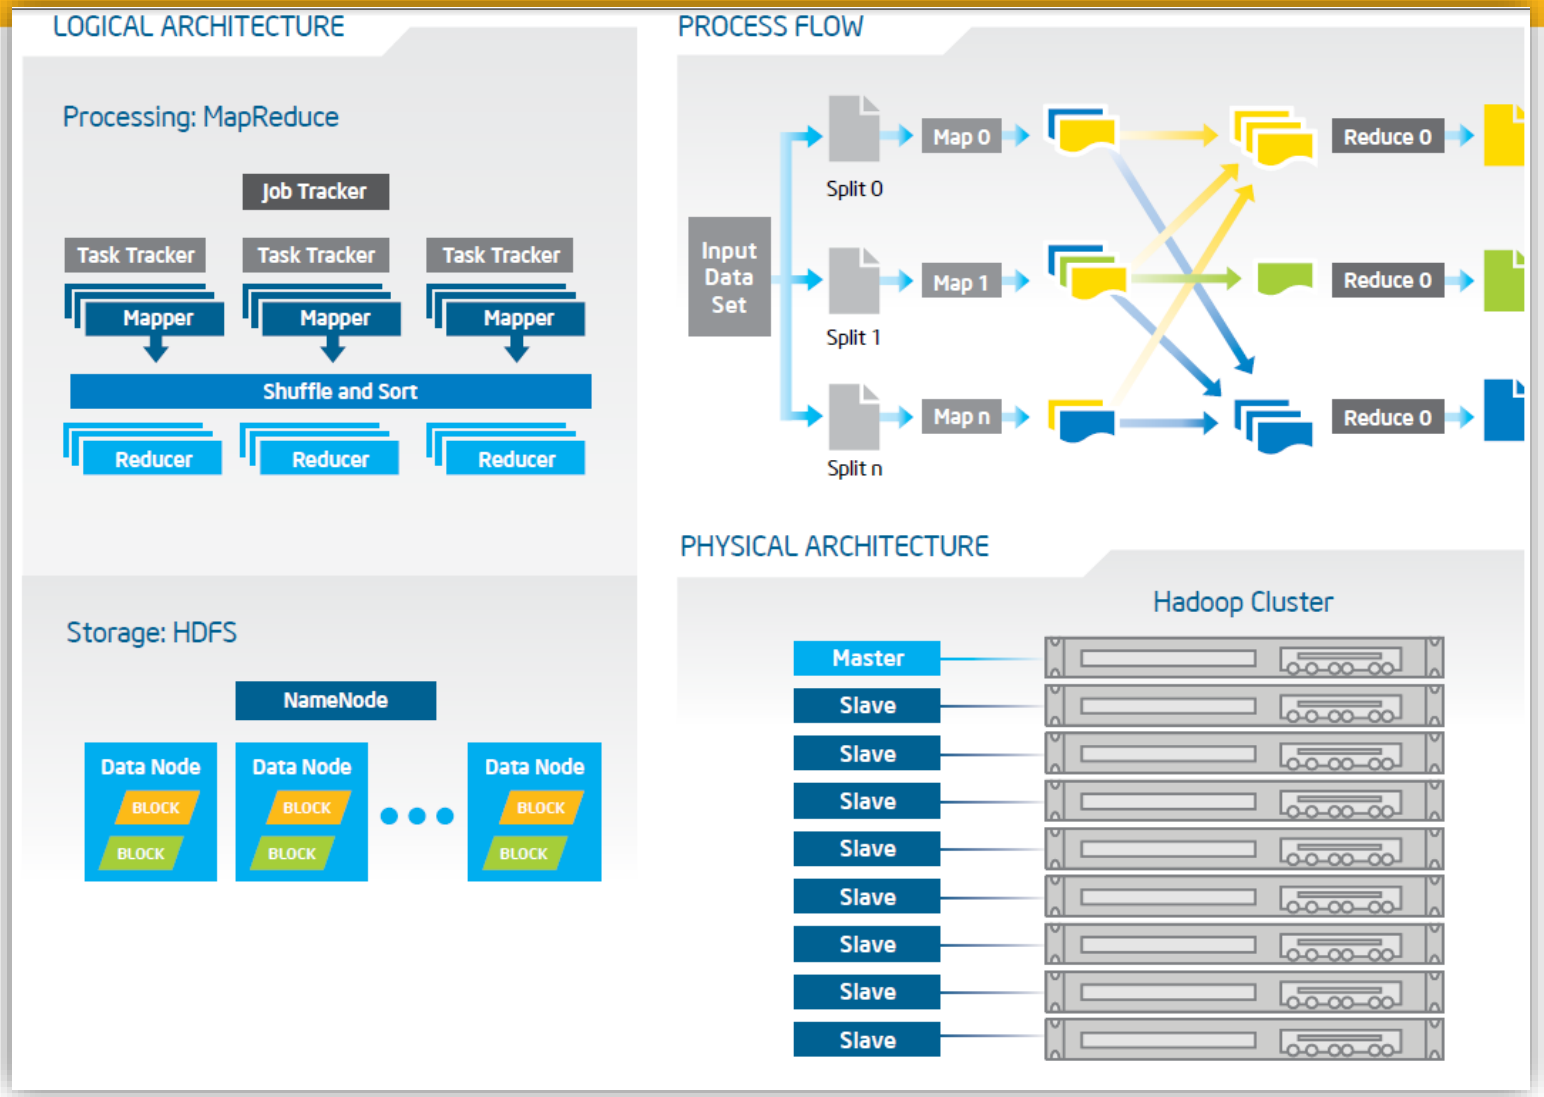

***Características:***

- *Alta Disponibilidad*
- *Acceso de Datos Streaming*
- *Grandes conjuntos de datos*
- *Modelo simple Coherencia:*
- *Computación en movimiento es más barato que Traslado de datos*
- *Portabilidad a través de hardware y software en plataformas heterogéneas*

# HDFS


Very Large Data File
Block 1
Block 2
Block 3
Block 1
Block 3
Block 1
Block 2
Block 2
Block 3
Block 2
Block 1
Block 3

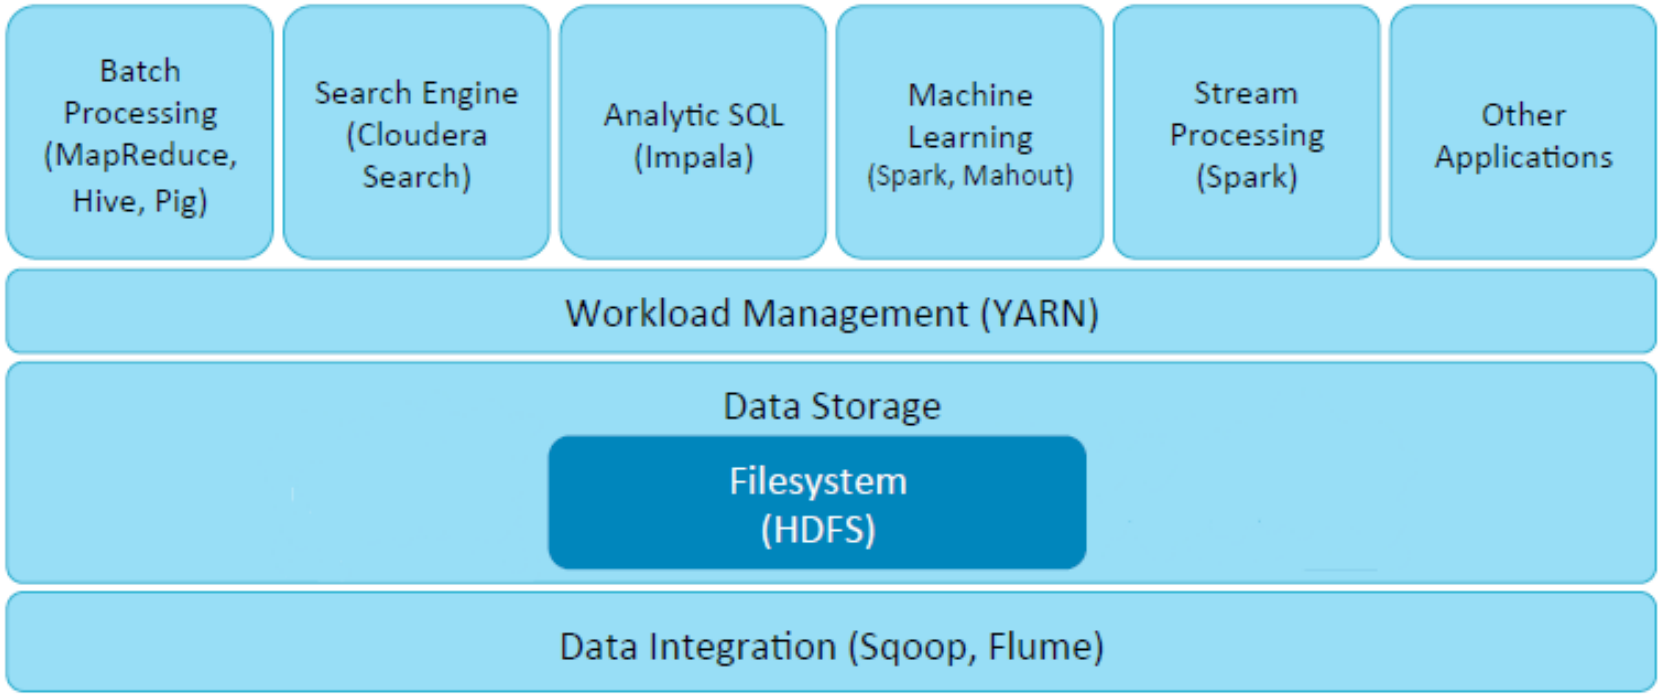
# HDFS

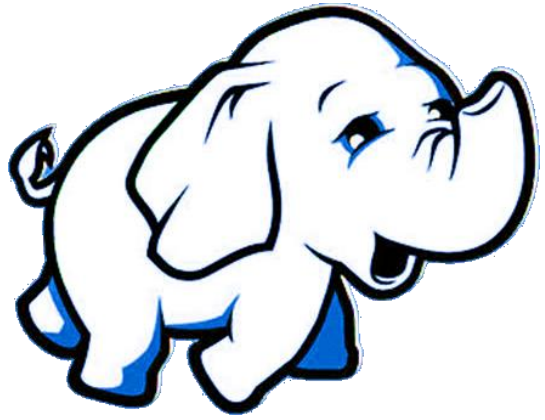



Fuente: Intel - big-data-get-started-reference-guide

# ARQUITECTURA DE DATOS HADOOP

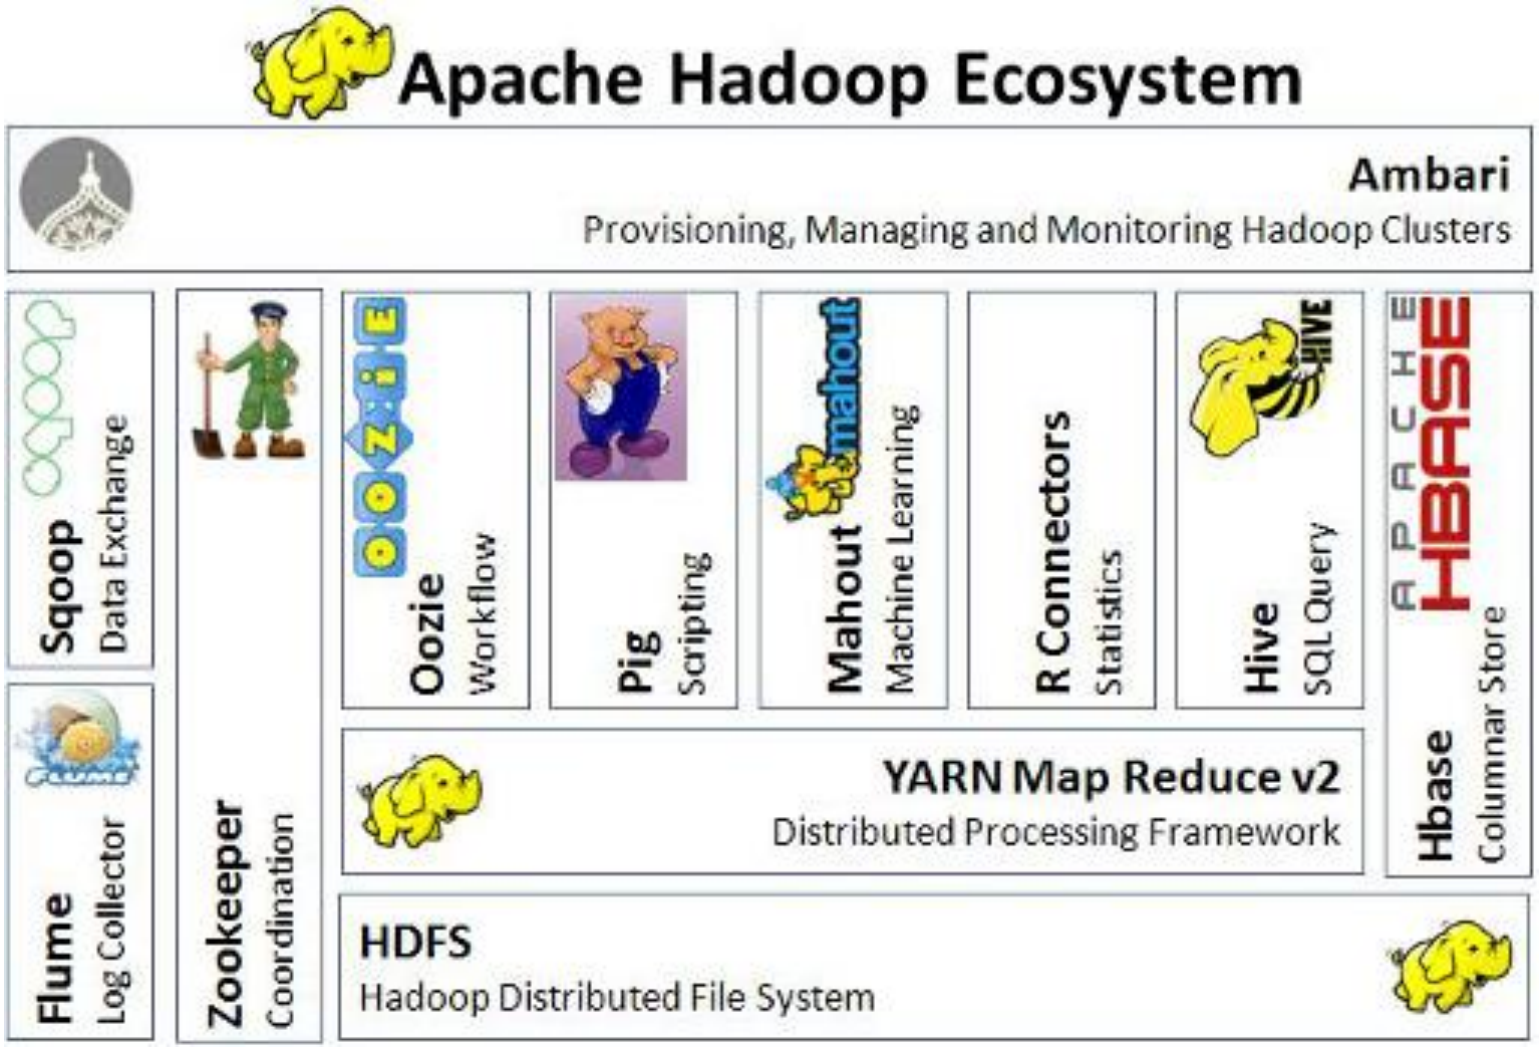




Fuentes:
Cloudera_Data_Analyst_Training
Hortonworks - Data Architecture with Apache

# ARQUITECTURA DE DATOS



# COMPONENTES ECOSISTEMA HADOOP

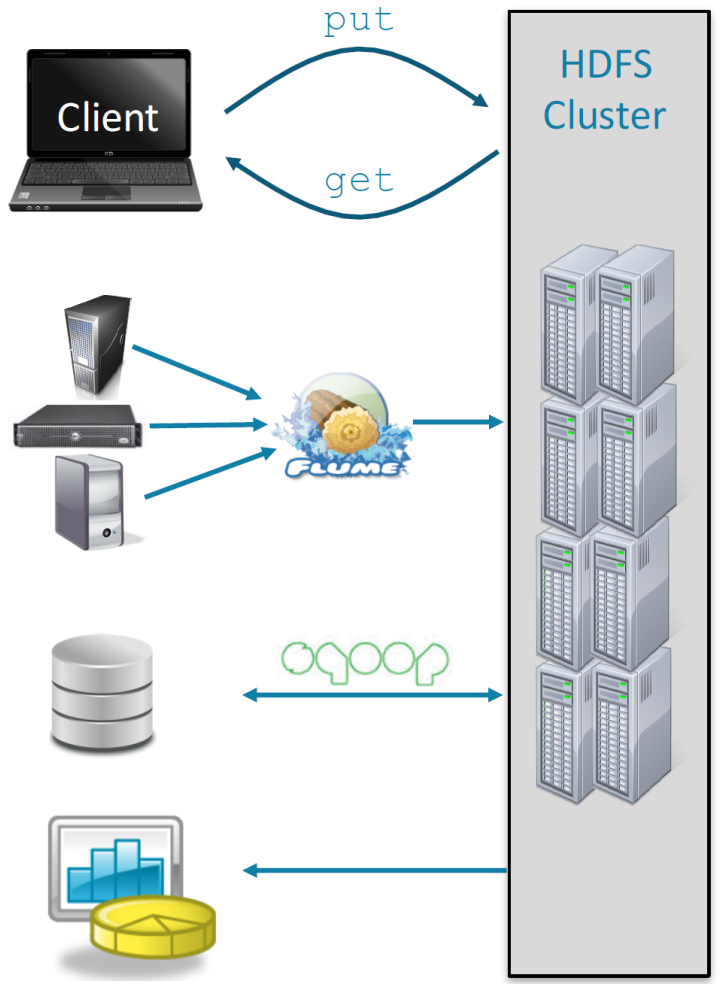


| Project | What does it do? |
|---|---|
| **Spark** | In-memory execution framework |
| **HBase** | NoSQL database built on HDFS |
| **Hive** | SQL processing engine designed for batch workloads |
| **Impala** | SQL query engine designed for BI workloads |
| **Parquet** | Very efficient columnar data storage format |
| **Sqoop** | Data movement to/from RDBMSs |
| **Flume, Kafka** | Streaming data ingestion |
| **Solr** | Enables users to find the data they need |
| **Hue** | Web-based user interface for Hadoop |
| **Oozie** | Workflow scheduler used to manage jobs |
| **Sentry** | Authorization tool, providing security for Hadoop |

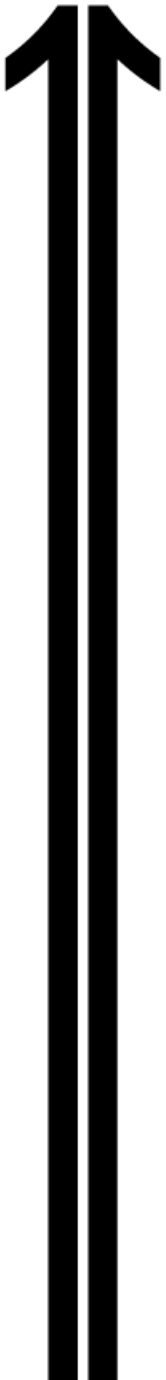
# ARQUITECTURA DE DATOS

## Ingestando o extayendo información

- **Hadoop**
  - Copies data between client (local) and HDFS (cluster)
  - API or command line
- **Ecosystem Projects**
  - Flume
    - Collects data from network sources (such as, websites, system logs)
  - Sqoop
    - Transfers data between HDFS and RDBMSs
- **Business Intelligence Tools**



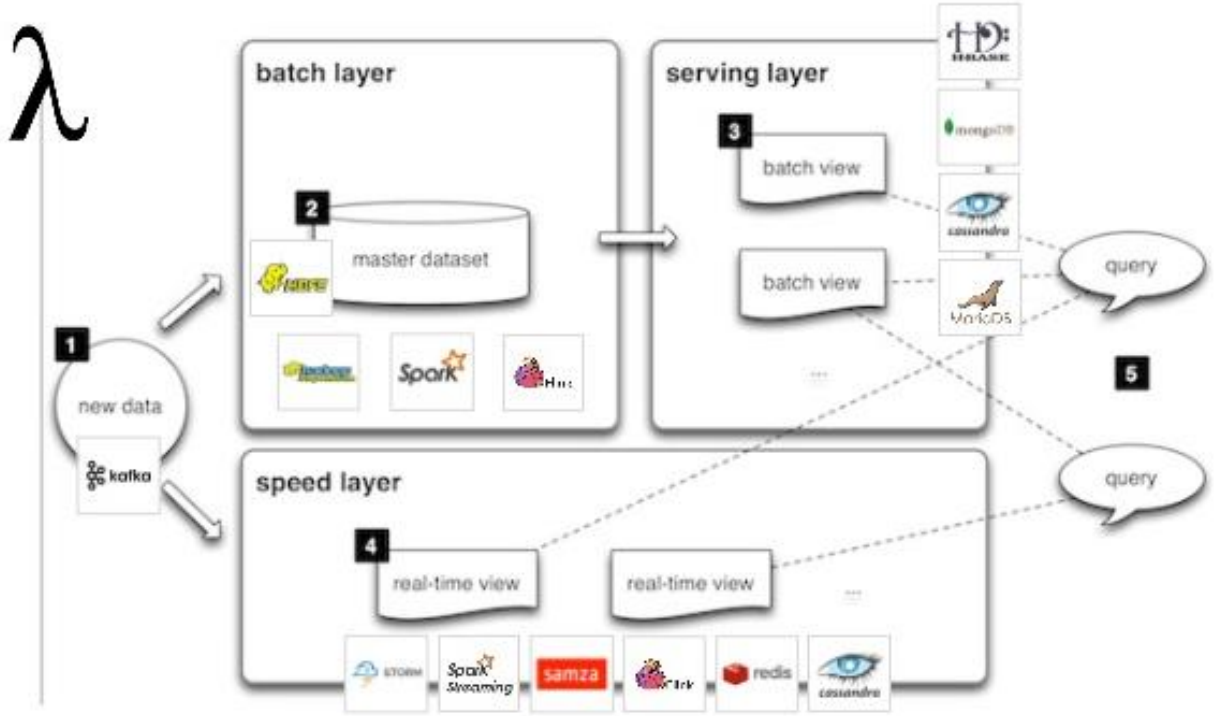

RDBMS: Relational Database Management System



# Arquitectura de datos

# ARQUITECTURA DE DATOS

## Lambda Architecture




Big Data
Principles and best practices of scalable realtime data systems
Nathan Marz and James Warren



# ARQUITECTURA DE DATOS



La arquitectura de datos en big data consta de varios componentes, que incluyen la capa de almacenamiento, la capa de procesamiento y la capa de presentación.

La capa de **almacenamiento** se utiliza para almacenar datos, ya sea en forma de archivos, bases de datos, o sistemas de almacenamiento distribuido como Hadoop Distributed File System (HDFS).

La capa de **procesamiento** es responsable del procesamiento de datos, que puede incluir transformación, análisis, limpieza y agregación. Esta capa se utiliza para llevar a cabo tareas de procesamiento masivo de datos utilizando herramientas de procesamiento distribuido como Apache Spark.

Finalmente, la capa de **presentación** se utiliza para visualizar los datos y proporcionar información útil a los usuarios finales. Esto puede implicar la creación de paneles de control, informes y visualizaciones interactivas

# COMPONENTES

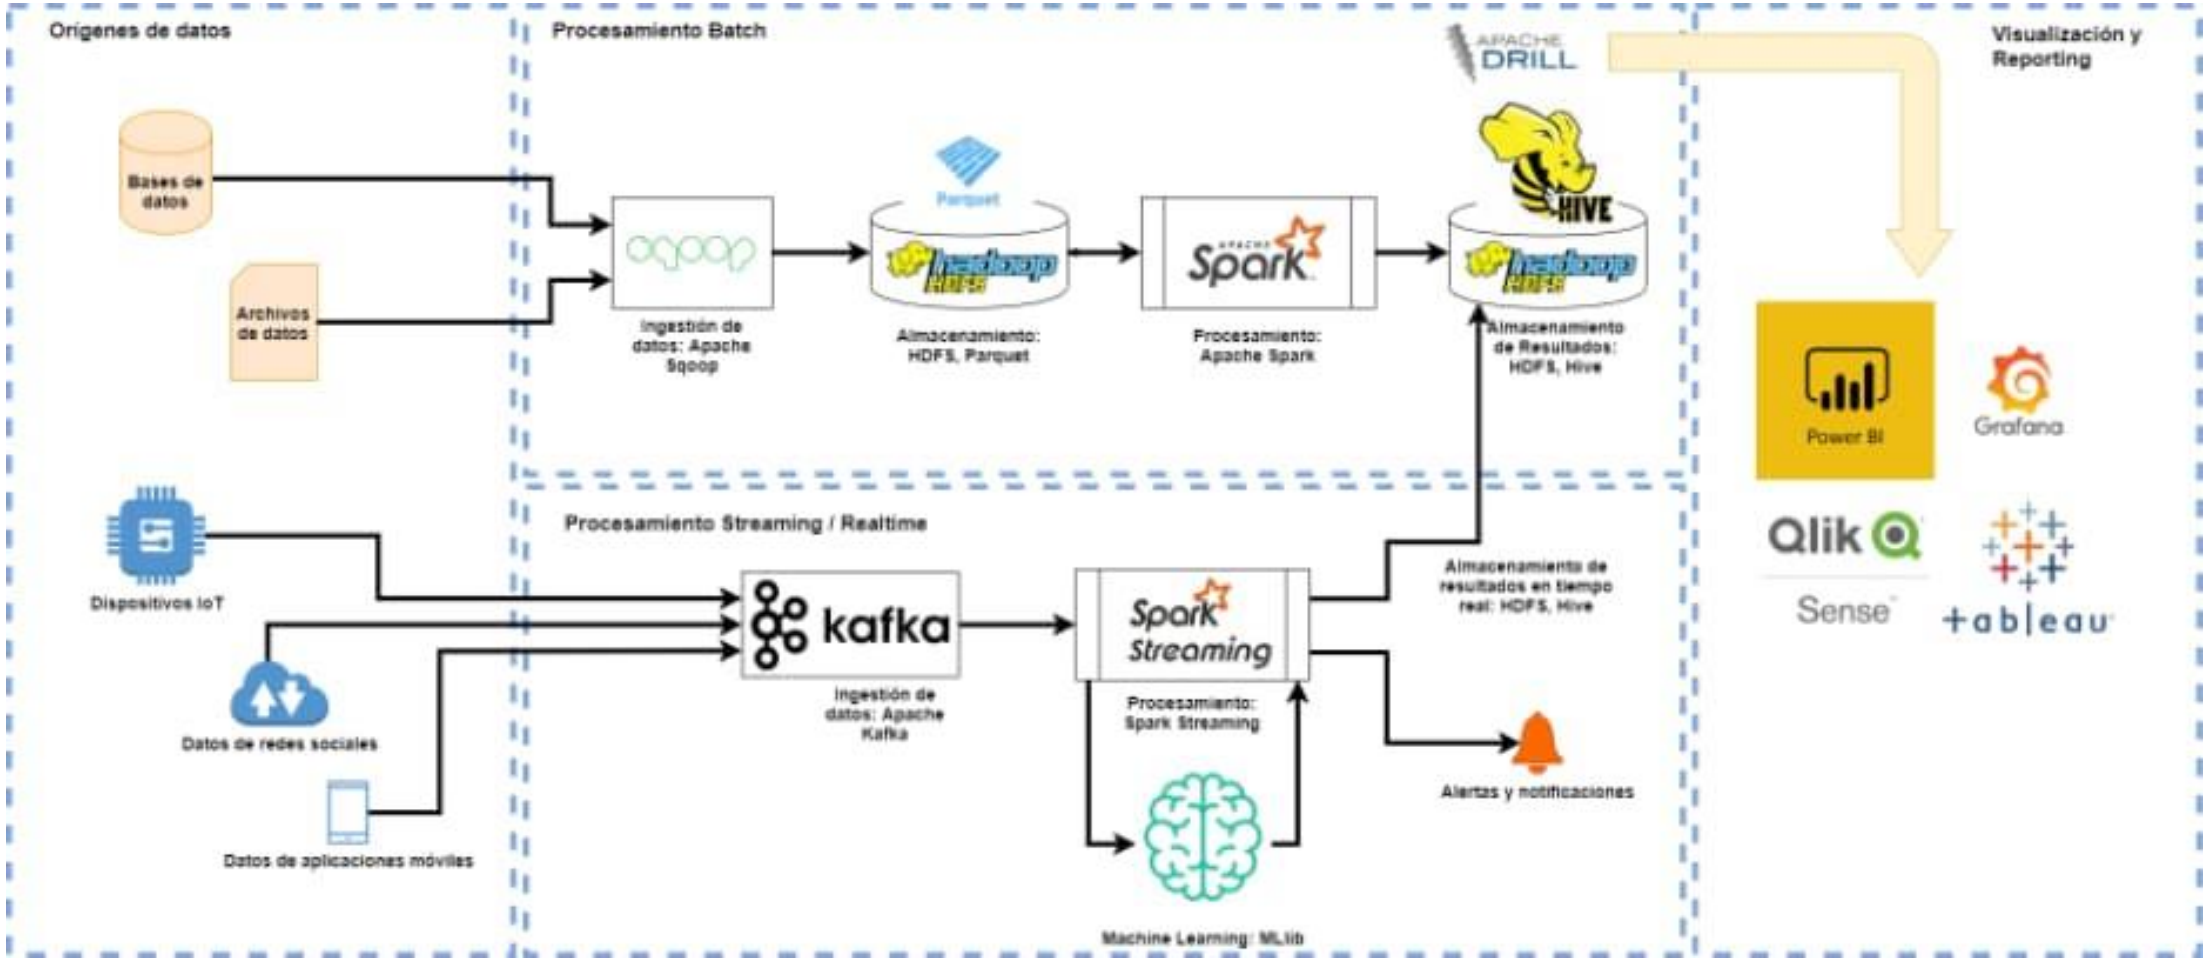


1.Capa de almacenamiento:
- Hadoop Distributed File System (HDFS)
- Apache HBase
- Cassandra
- Amazon S3
- MongoDB
- Redis

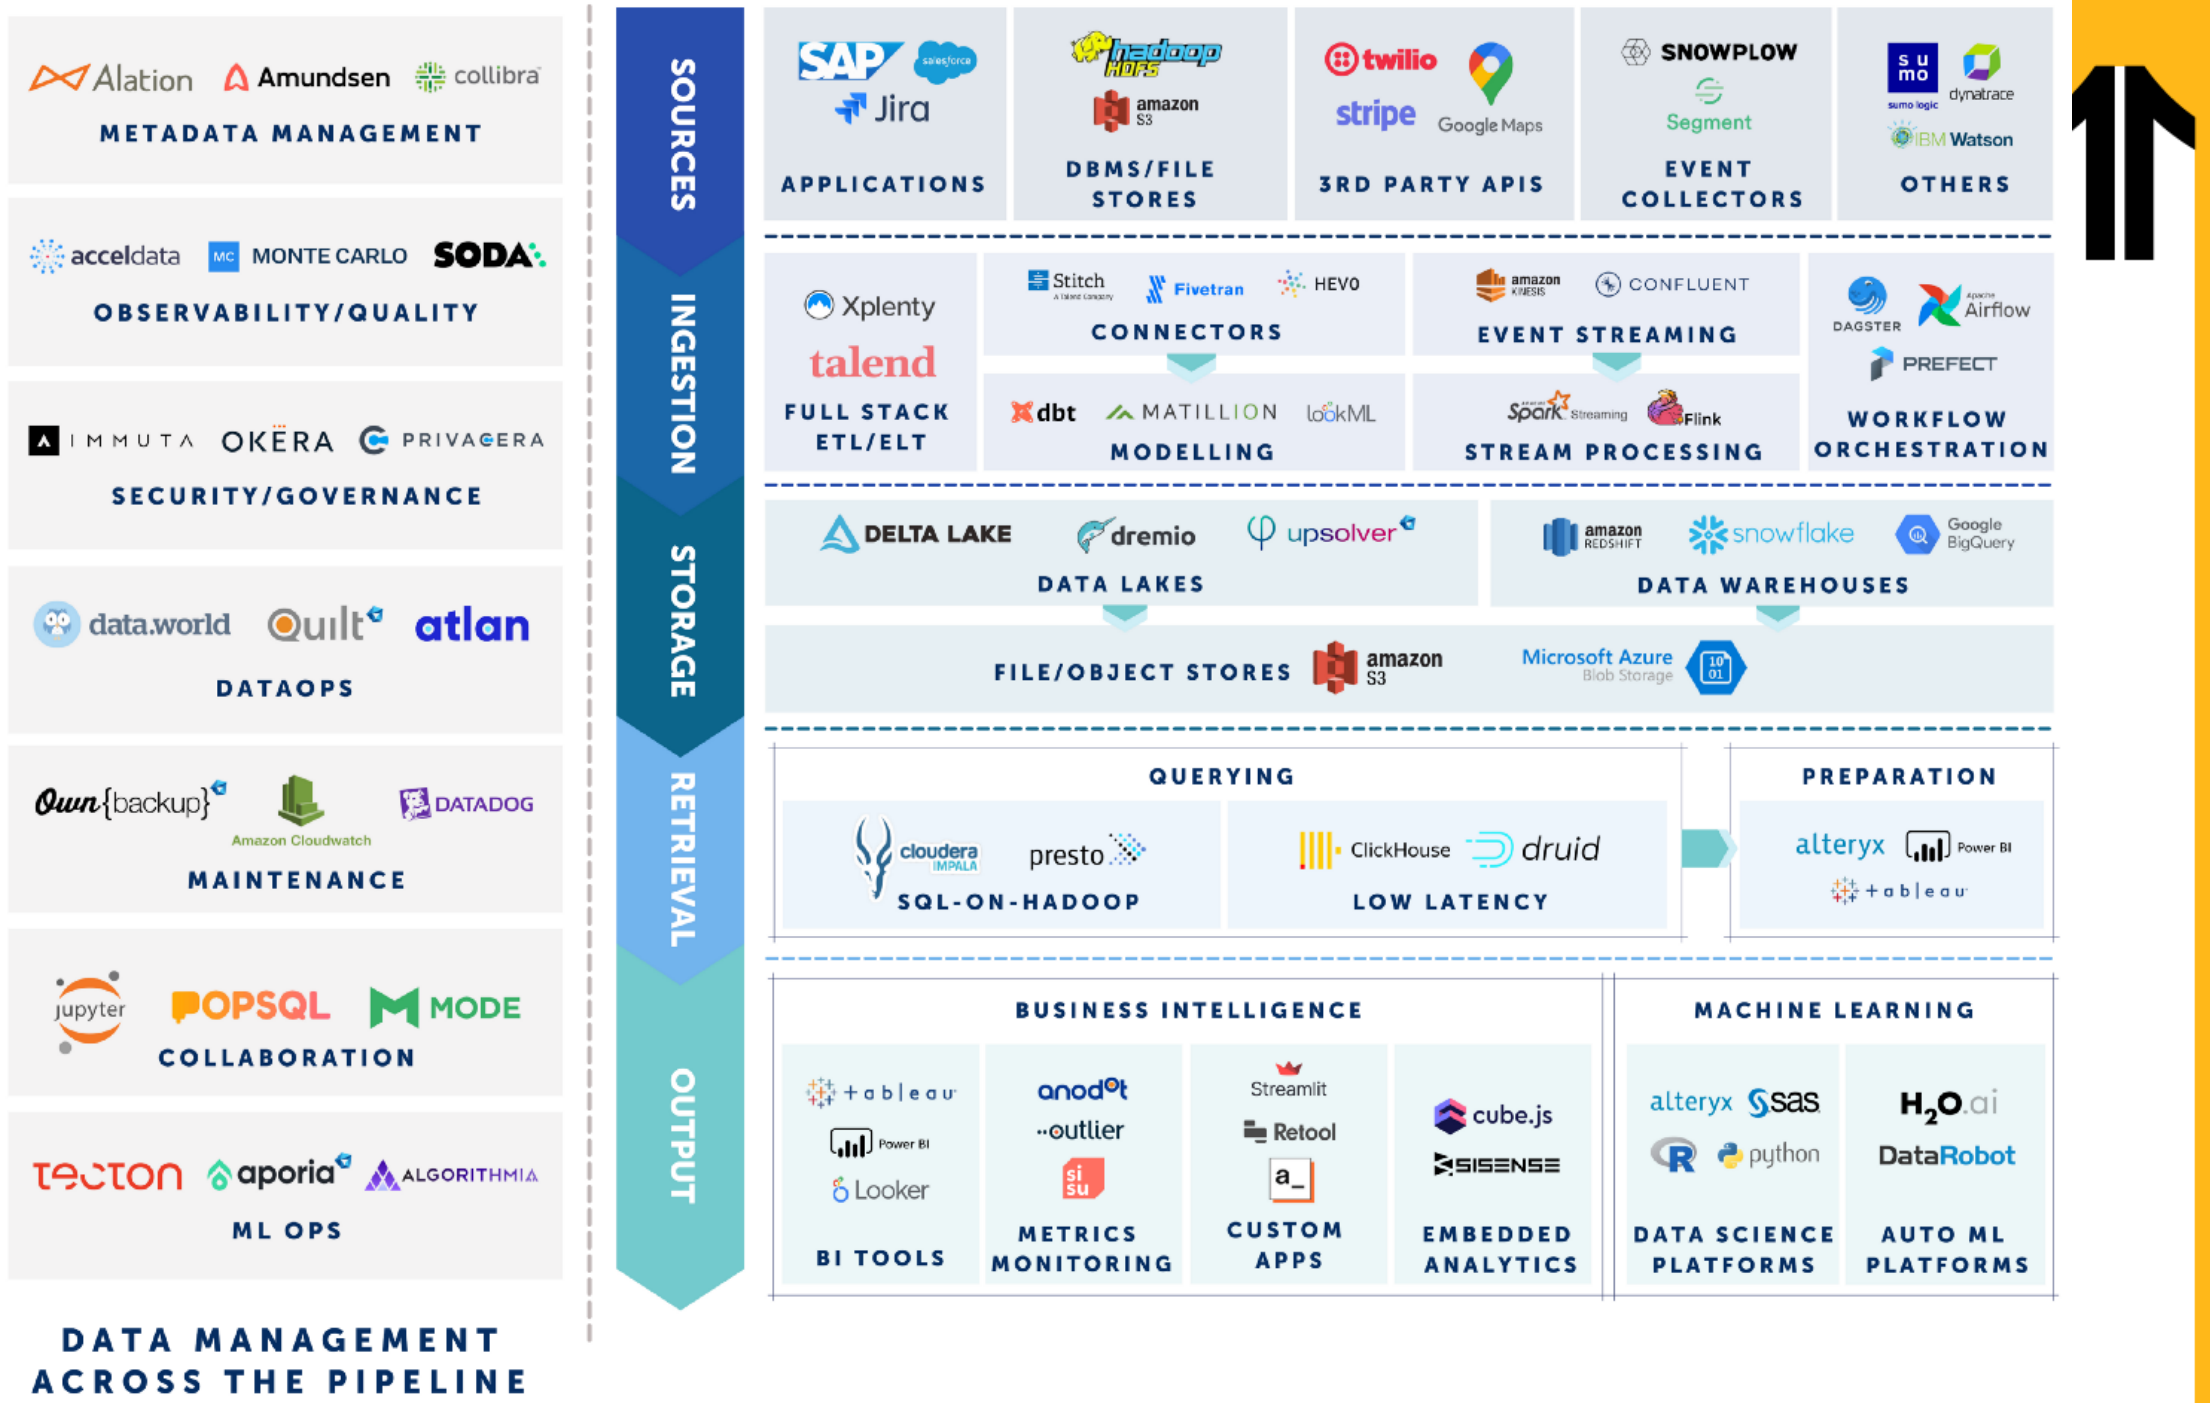
2.Capa de procesamiento:
- Apache Spark
- Apache Flink
- Apache Storm
- Apache Beam
- Apache Kafka
- Amazon EMR

3.Capa de presentación:
- Tableau
- Power BI
- QlikView
- Apache Zeppelin
- D3.js
- Plotly

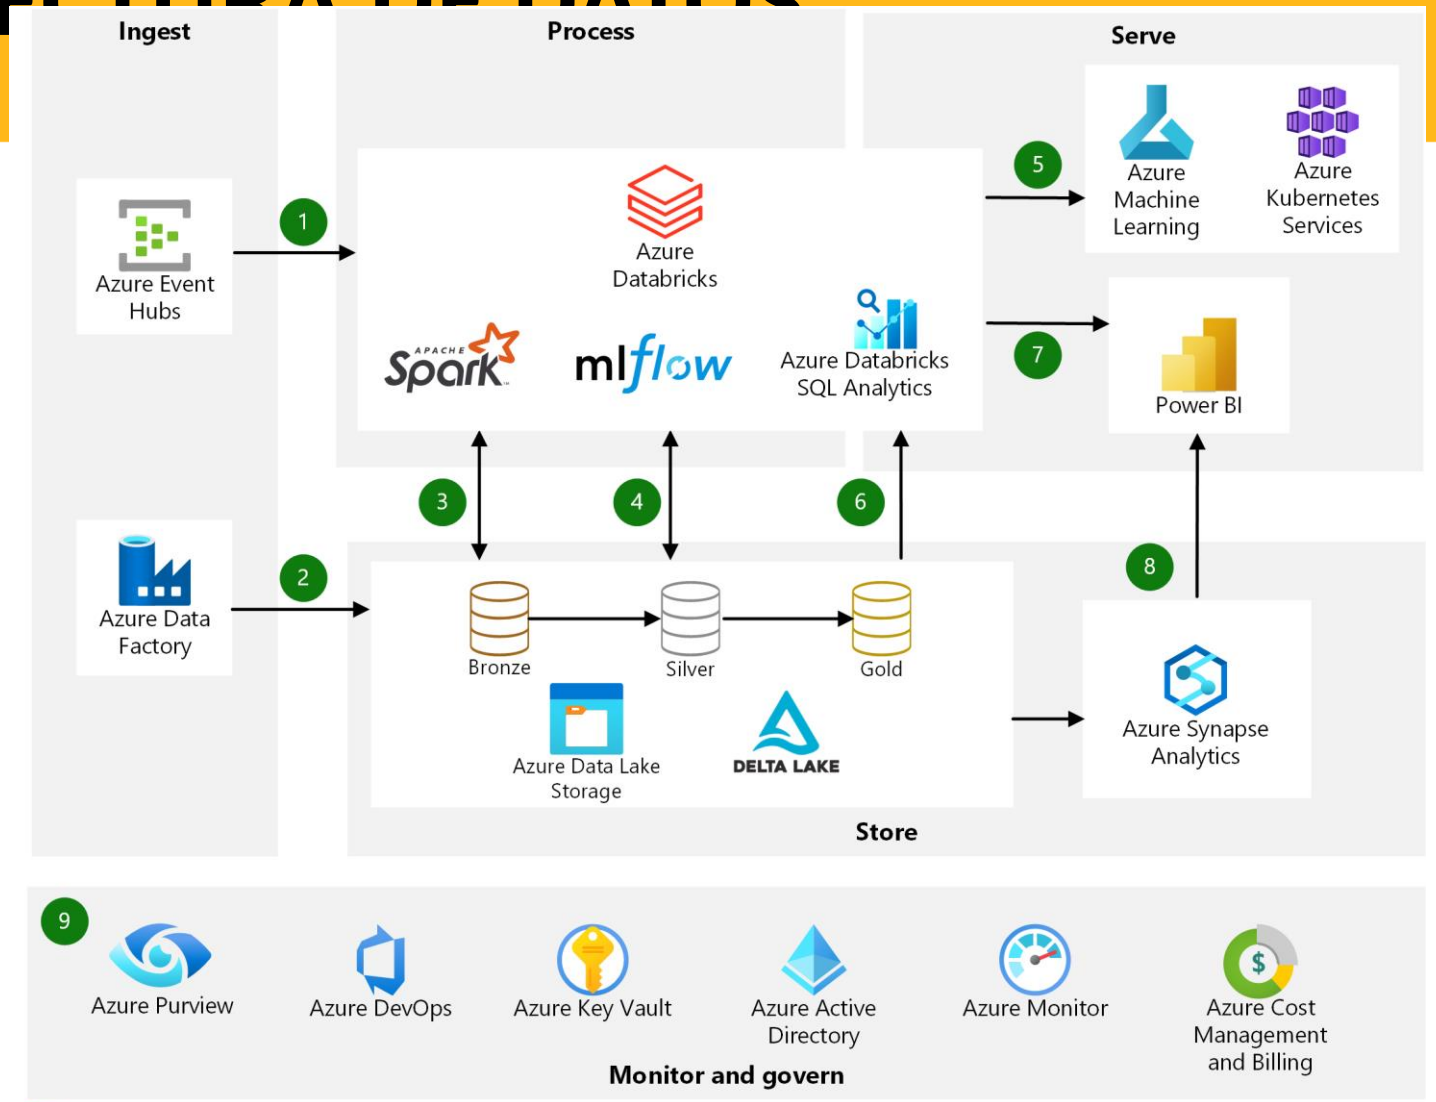
# ARQUITECTURA DE DATOS



ARC


Alation
Amundsen
collibra
METADATA MANAGEMENT
acceldata
MONTE CARLO
SODA
OBSERVABILITY/QUALITY
IMMUTA
OKERA
PRIVACERA
SECURITY/GOVERNANCE
data.world
Quilt
atlan
DATAOPS
Own{backup}
Amazon Cloudwatch
DATADOG
MAINTENANCE
jupyter
POPSQL
MODE
COLLABORATION
tecton
aporia
ALGORITHMIA
ML OPS
DATA MANAGEMENT ACROSS THE PIPELINE
SOURCES
INGESTION
STORAGE
RETRIEVAL
OUTPUT
SAP
salesforce
Jira
APPLICATIONS
hadoop HDFS
amazon S3
DBMS/FILE STORES
twilio
stripe
Google Maps
3RD PARTY APIS
SNOWPLOW
Segment
EVENT COLLECTORS
sumo logic
dynatrace
IBM Watson
OTHERS
Xplenty
talend
FULL STACK ETL/ELT
Stitch
Fivetran
HEVO
CONNECTORS
dbt
MATILLION
lookML
MODELLING
amazon KINESIS
CONFLUENT
EVENT STREAMING
Spark Streaming
Flink
STREAM PROCESSING
DAGSTER
Airflow
PREFECT
WORKFLOW ORCHESTRATION
DELTA LAKE
dremio
upsolver
DATA LAKES
amazon REDSHIFT
snowflake
Google BigQuery
DATA WAREHOUSES
FILE/OBJECT STORES
amazon S3
Microsoft Azure Blob Storage
QUERYING
cloudera IMPALA
presto
SQL-ON-HADOOP
ClickHouse
druid
LOW LATENCY
PREPARATION
alteryx
Power BI
tableau
BUSINESS INTELLIGENCE
tableau
Power BI
Looker
BI TOOLS
anodot
outlier
METRICS MONITORING
Streamlit
Retool
CUSTOM APPS
cube.js
SISENSE
EMBEDDED ANALYTICS
MACHINE LEARNING
alteryx
SAS
python
DATA SCIENCE PLATFORMS
H2O.ai
DataRobot
AUTO ML PLATFORMS

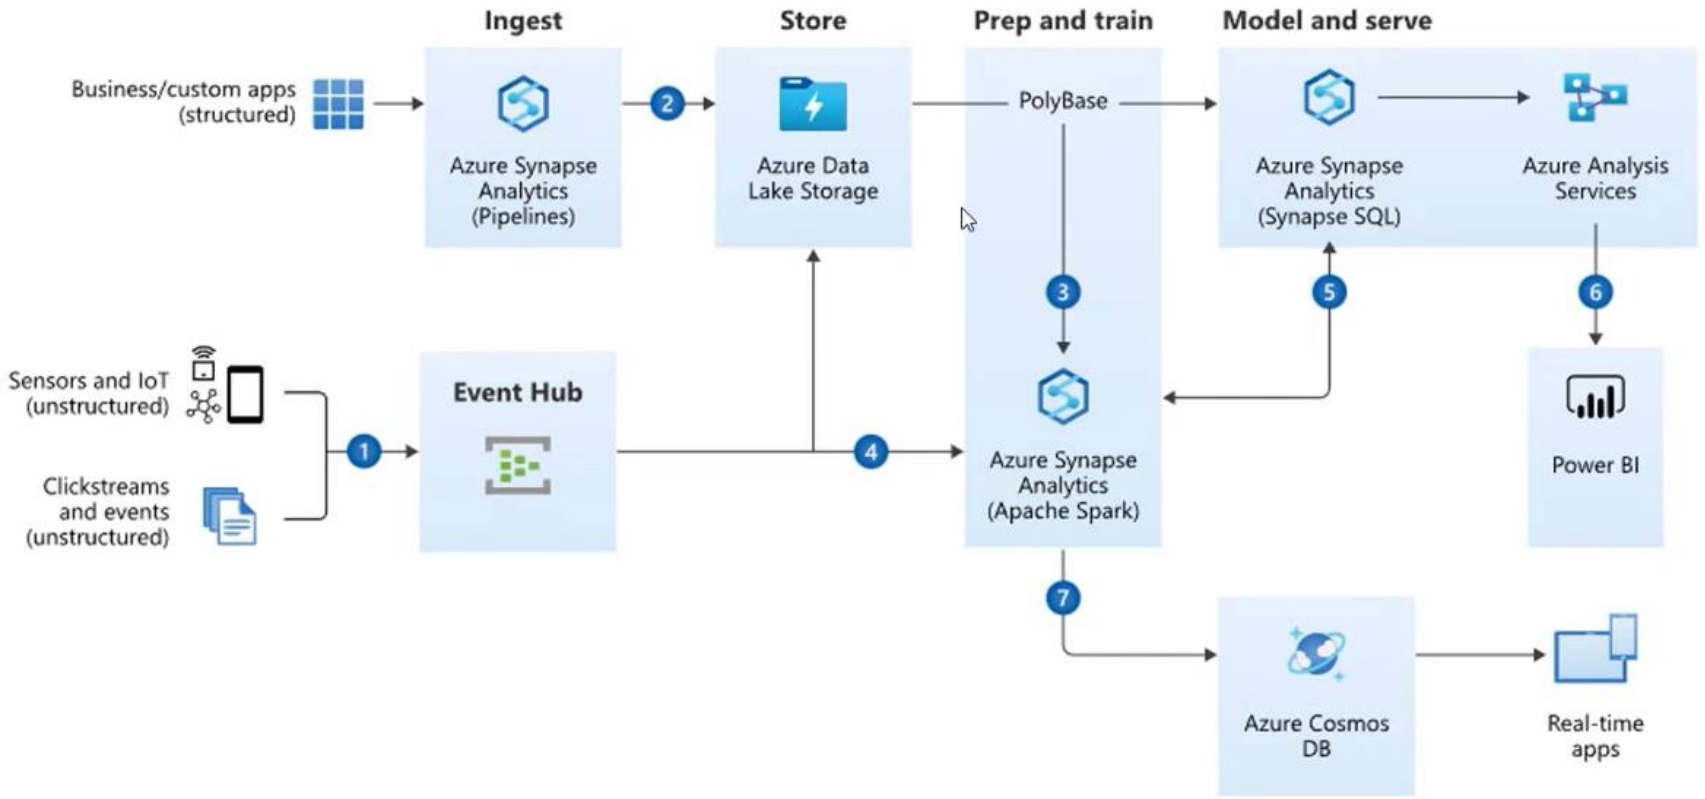
# ARQUITECTURA DE DATOS




https://learn.microsoft.com/es-es/azure/architecture/solution-ideas/articles/azure-databricks-modern-analytics-architecture

# ARQUITECTURA DE DATOS

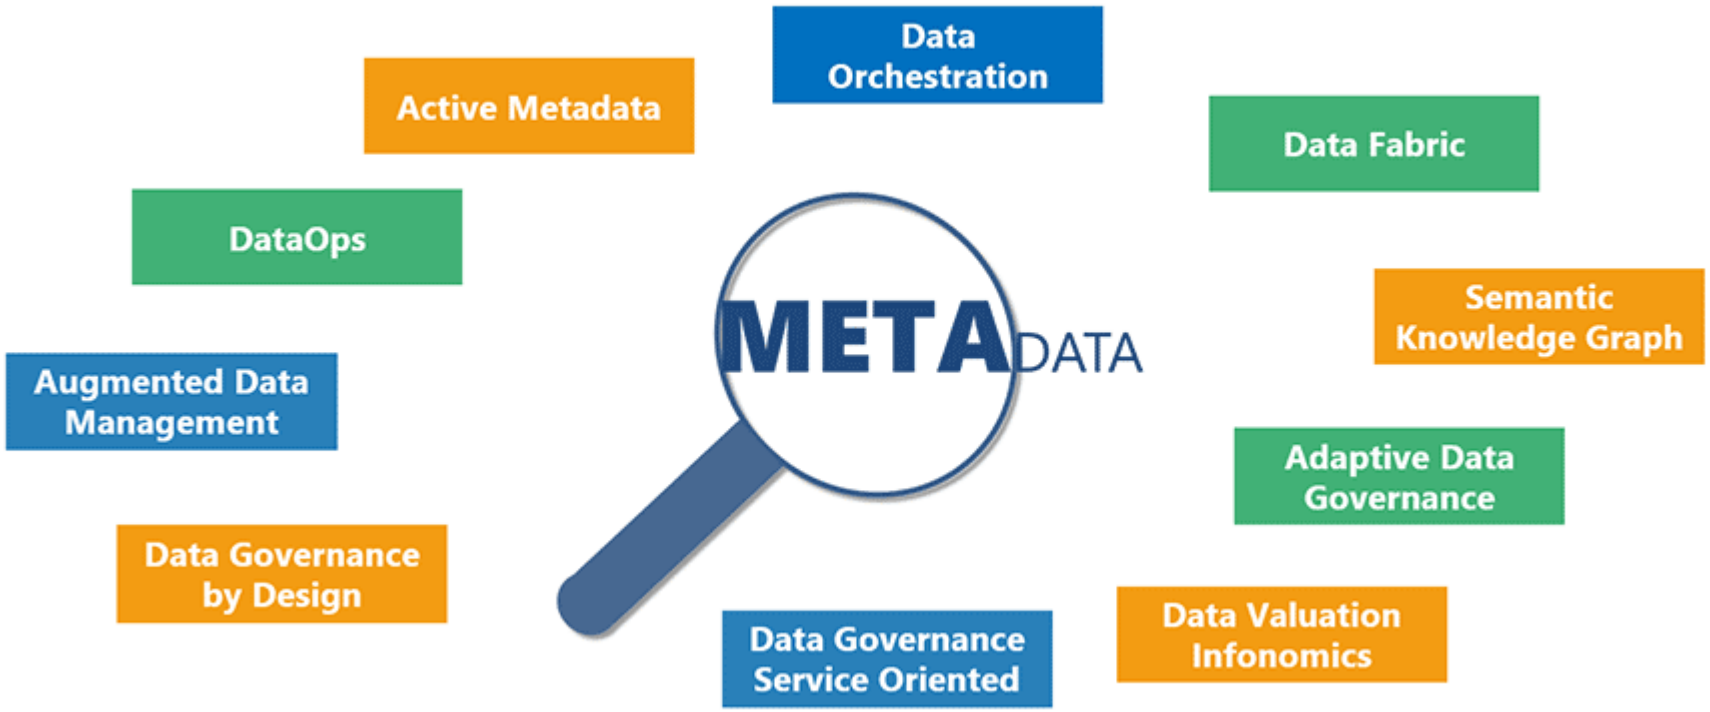
Análisis en tiempo real




## Productos

- Azure Synapse Analytics
- Azure Analysis Services
- Power BI Embedded
- Cuentas de almacenamiento
- Azure Cosmos DB
- Event Hubs

# METADATOS


Data Orchestration
Active Metadata
Data Fabric
DataOps
METADATA
Semantic Knowledge Graph
Augmented Data Management
Adaptive Data Governance
Data Governance by Design
Data Valuation Infonomics
Data Governance Service Oriented

# METADATOS

La arquitectura de metadatos se refiere al diseño y estructura de los sistemas de información que almacenan y gestionan los metadatos de una organización. Los metadatos son información adicional sobre los datos, como su origen, formato, fecha de creación, descripción, calidad, entre otros aspectos. La arquitectura de metadatos se enfoca en cómo se almacenan, procesan y distribuyen estos metadatos, para permitir una gestión más eficiente de los datos y su utilización por parte de las distintas aplicaciones y usuarios.

La arquitectura de metadatos incluye una serie de componentes y procesos, como la definición de esquemas de metadatos, la gestión de metadatos en bases de datos especializadas, la implementación de herramientas de catalogación y búsqueda de metadatos, y la integración de los metadatos en los sistemas de análisis y procesamiento de datos.




METADATOS

# METADATOS

1.Herramientas de **modelado de metadatos**: permiten definir esquemas de metadatos y relaciones entre ellos, como por ejemplo IBM InfoSphere Information Server, Oracle Enterprise Metadata Management, y Talend Open Studio.

2.Sistemas de **gestión de metadatos**: son bases de datos especializadas para almacenar y gestionar metadatos, como Apache Atlas, Collibra, Informatica Metadata Manager, y SAP Master Data Governance.

3.Herramientas de **catalogación y búsqueda de metadatos**: permiten etiquetar, clasificar y buscar metadatos, como Apache NiFi, Informatica Enterprise Data Catalog, y Talend Metadata Manager.

# AMENAZAS



Password cracking

Escalamiento de privilegios

Fraudes informáticos

Puertos vulnerables abiertos

Exploits

Man in the middle

Violación de la privacidad de los empleados

Servicios de log inexistentes o que no son chequeados

Backups inexistentes

Denegación de servicio

Destrucción de equipamiento

Últimos parches no instalados

Instalaciones default

Desactualización

Keylogging

Port scanning

Hacking de Centrales Telefónicas

# SEGURIDAD

La **seguridad de la información** tiene como propósito **proteger** la información registrada, **independientemente** del lugar en que se localice: *impresos en papel, en los discos duros de las computadoras o incluso en la memoria de las personas que las conocen*.




Sistema de Gestión de Seguridad de la Información
http://www.bajacg.com/uncategorized/iso-27000/

# SEGURIDAD DE LA INFORMACIÓN

La seguridad de la información se caracteriza aquí como la preservación de:

| | |
|---|---|
| Confidencialidad | • asegurando que sólo quienes estén autorizados pueden acceder a la información |
| Integridad | • asegurando que la información y sus métodos de proceso son exactos y completos |
| Disponibilidad | • asegurando que los usuarios autorizados tienen acceso a la información y a sus activos asociados cuando lo requieran |

# GESTIÓN DE SEGURIDAD



Para lograr una adecuada gestión de seguridad en big data, se pueden seguir los siguientes pasos:
1.Identificar y evaluar los riesgos.

2.Definir políticas y procedimientos de seguridad.

3.Implementar medidas de seguridad técnicas.

4.Realizar auditorías de seguridad.

5.Capacitación y concientización de usuarios.

Es importante tener en cuenta que la gestión de seguridad en un entorno de big data es un proceso continuo que debe ser monitoreado y actualizado regularmente para adaptarse a los cambios en el entorno y a las nuevas amenazas de seguridad.

# TECNOLOGÍAS DE SEGURIDAD



1.Plataformas de seguridad de big data: estas plataformas ofrecen soluciones de seguridad específicas para el entorno de big data, como Apache Ranger, Cloudera Navigator y Hortonworks DataPlane Service.
2.Herramientas de cifrado y enmascaramiento de datos: estas herramientas permiten proteger los datos confidenciales mediante técnicas de cifrado y enmascaramiento, como Apache Atlas, Protegrity y Vormetric.
3.Herramientas de autenticación y autorización: estas herramientas permiten autenticar y autorizar a los usuarios para acceder a los datos en el entorno de big data, como Apache Knox, Okta y Ping Identity.
4.Herramientas de monitoreo y análisis de seguridad: estas herramientas permiten monitorear y analizar las actividades en el entorno de big data en tiempo real, para detectar posibles amenazas y vulnerabilidades, como Apache Metron, RSA Security Analytics y Splunk.
5.Herramientas de gestión de políticas de seguridad: estas herramientas permiten definir y gestionar políticas de seguridad en el entorno de big data, como IBM Security Guardium, Oracle Audit Vault and Database Firewall y SAP Enterprise Threat Detection.

# ¿Preguntas o comentarios?



# CONCLUSIONES

Bigdata a permitido a las organización poder gestionar grandes volúmenes de datos de manera rápida y aportando valor

Hadoop es un framework basado en Hardware y Software para el procesamiento distribuido, además es open source.

Las arquitecturas modernas de Bigdata integran el uso de Cloud Computing



# REFERENCIAS BIBLIOGRÁFICAS

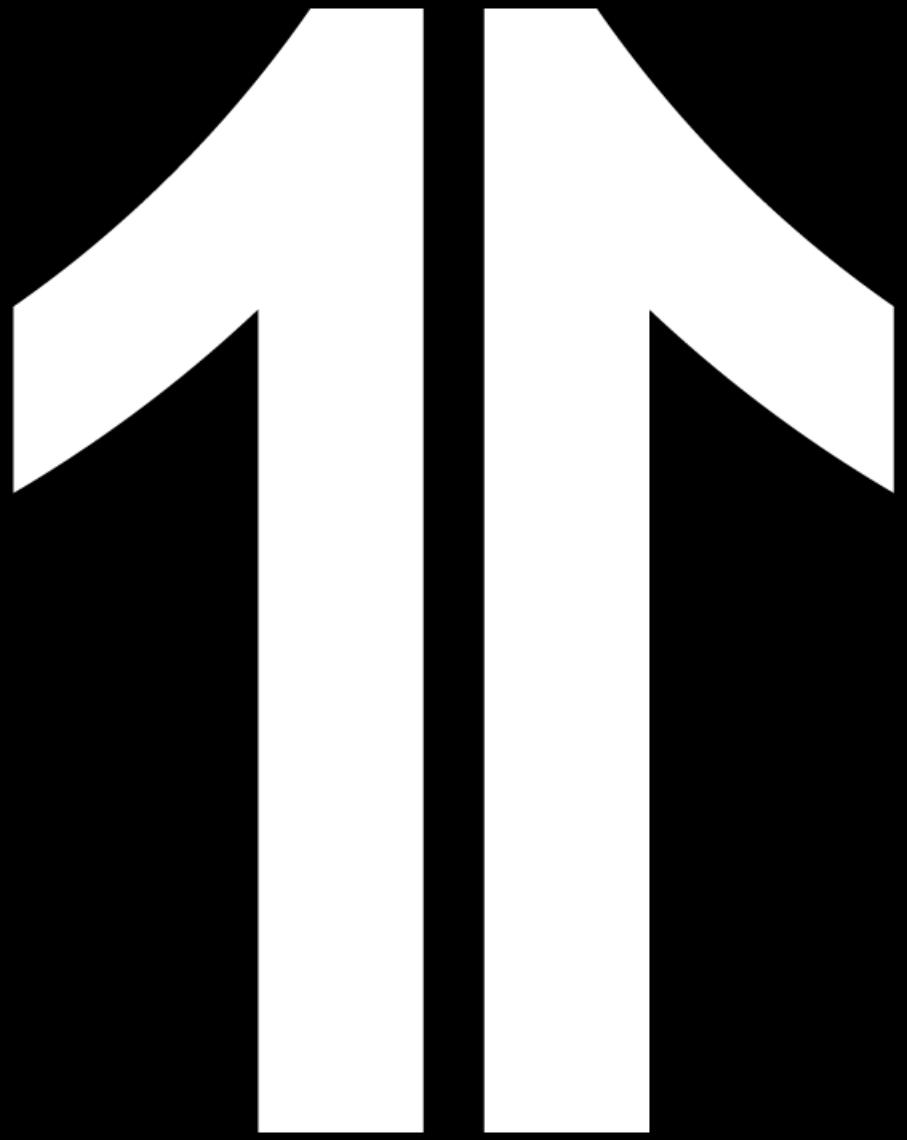

BIGDATA
https://www.oracle.com/pe/big-data/what-is-big-data/#:~:text=Definici%C3%B3n%20de%20big%20data,-%C2%BFQu%C3%A9%20es%2C%20exactamente&text=El%20t%C3%A9rmino%20%E2%80%9Cbig%20data%E2%80%9D%20abarca,como%20%E2%80%9Clas%20tres%20V%E2%80%9D

Herramientas Big Data
https://todobi.com/tag/big-data/

Introducción a Azure Synapse analytics
https://learn.microsoft.com/es-es/training/modules/introduction-azure-synapse-analytics/

Arquitecturas Azure
https://learn.microsoft.com/en-us/azure/architecture/browse/

Demos
https://bigdata.stratebi.com/



GRACIAS


UPN
UNIVERSIDAD
PRIVADA
DEL NORTE