

BASE DE DATOS AVANZADAS Y BIG DATA

UPN.EDU.PE

Semana 11

Gestión de Datos con Spark

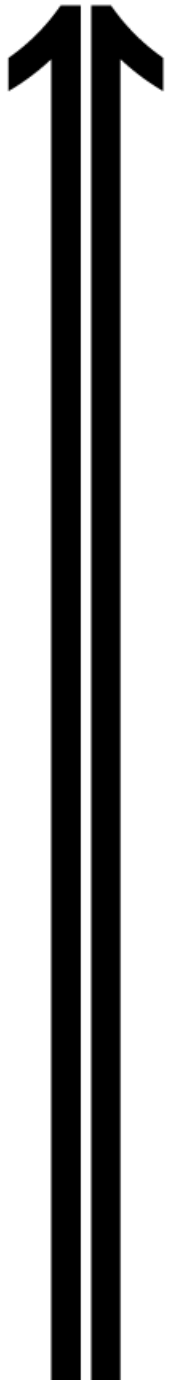
Presentación de la sesión

Logro de sesión

Al término de la sesión los estudiantes conocen los componentes de Apache Spark y como optimiza la gestión de datos, interactuando con Databricks.

Temario

- Gestión de Datos con Spark.



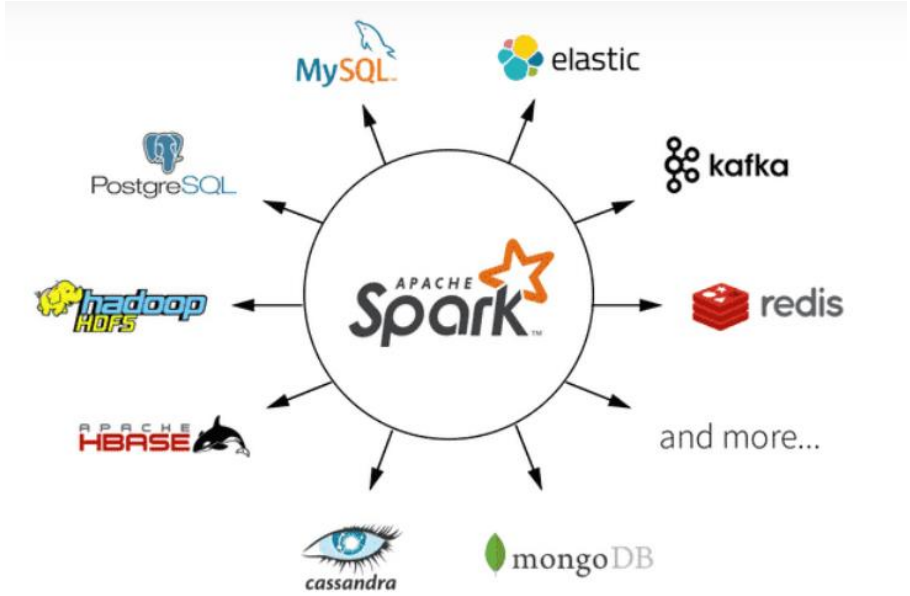
Apache SPARK

APACHE SPARK

Apache Spark es un framework de programación para procesar datos masivos o big data, de forma distribuida, diseñado para ser rápido

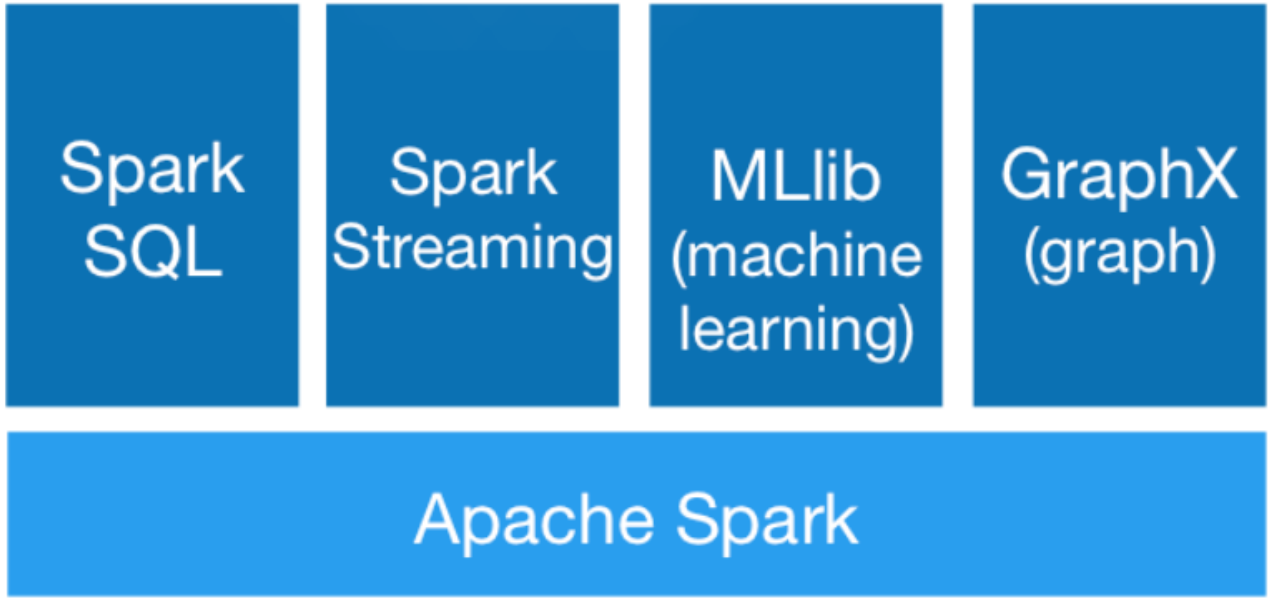
Spark no almacena datos, sino los procesa en memoria. Se diferencia de Hadoop en este punto porque incluye almacenamiento persistente (HDFS) y su sistema de procesamiento MapReduce.

Spark puede leer todo tipo de datos modernos como Amazon S3 o Google storage, además de sistemas distribuidos HDFS, sistemas de clave y valor como Apache Cassandra o sistemas de flujos de datos en tiempo real como Apache Kafka.



https://datademia.es/blog/que-es-apache-spark

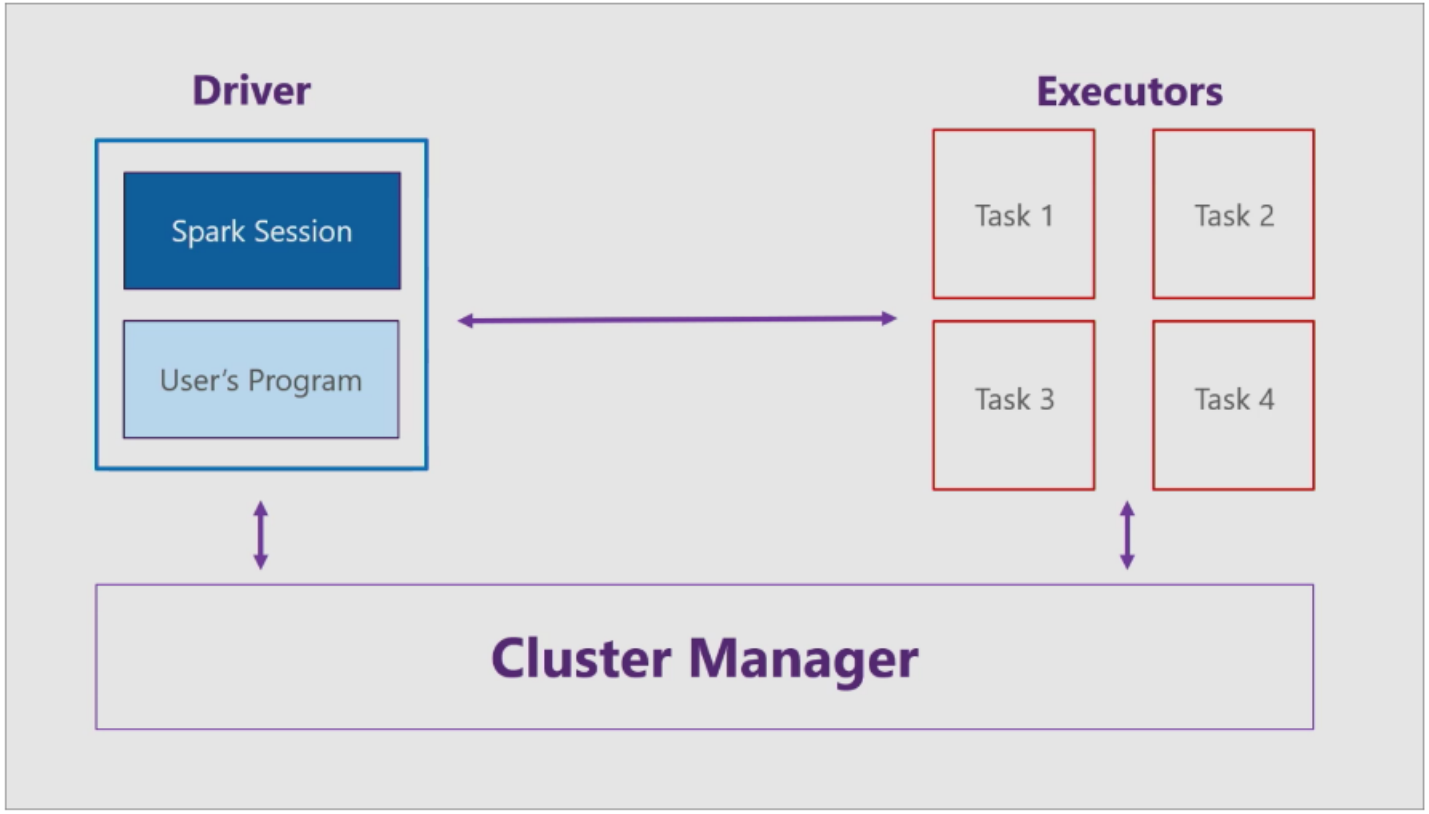
ECOSISTEMA DE SPARK





ARQUITECTURA SPARK

Apache Spark tiene tres componentes principales: el controlador, los ejecutores y el administrador de clústeres. Las aplicaciones Spark se ejecutan como conjuntos independientes de procesos en un clúster, coordinados por el programa de controladores



USO SPARK



- Cisco
- eBay
- Facebook
- IBM
- Microsoft
- NASA
- Netflix
- Nokia
- Samsung
- Shopify
- TripAdvisor
- Yahoo!

https://spark.apache.org/powered-by.html

SPARK



- **Múltiples formas de desplegar un clúster de Spark**











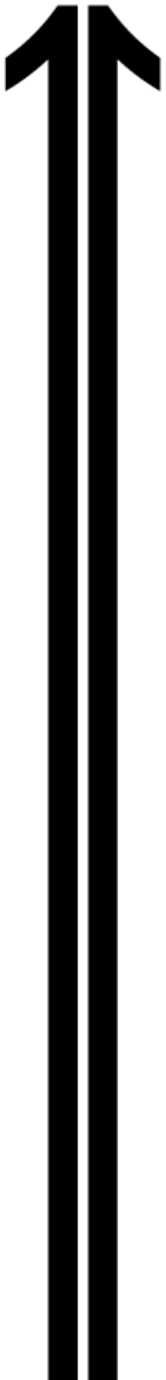






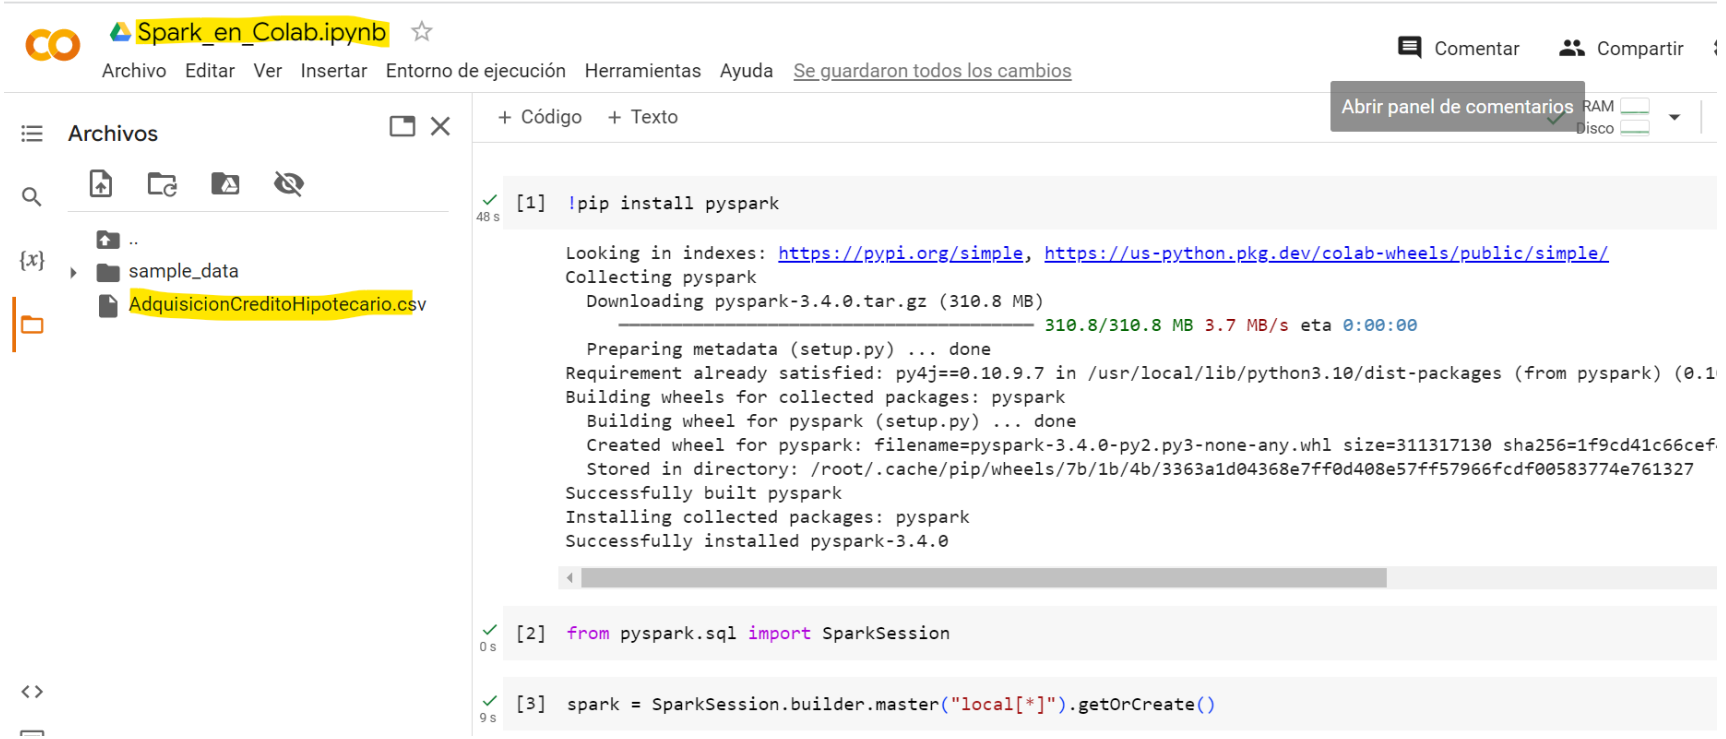
https://www.cloudera.com/

https://bigdata.stratebi.com/

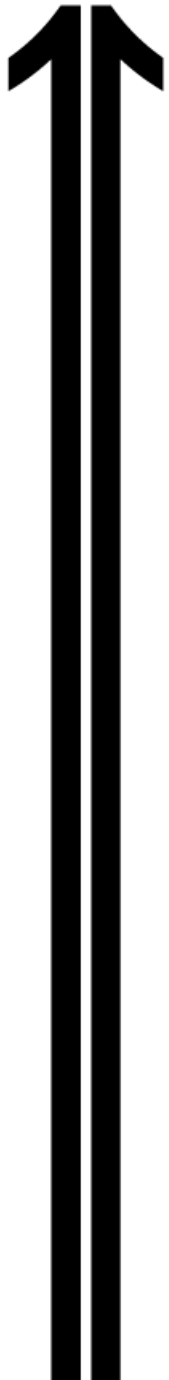


SPARK en Google Colab

SPARK EN COLAB (PYTHON)



Cargar el NB **Spark_en_Colab** y luego subir el archivo **AdquisicionCreditoHipotecario.csv**

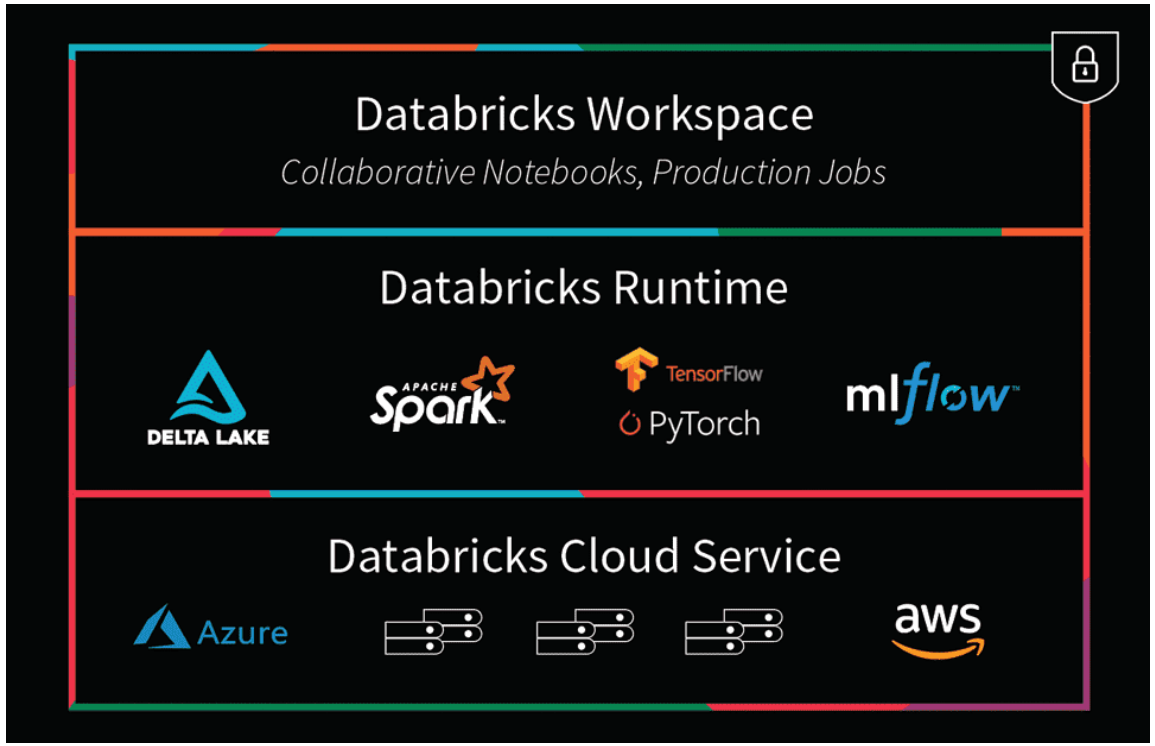


Databricks

DATABRICKS

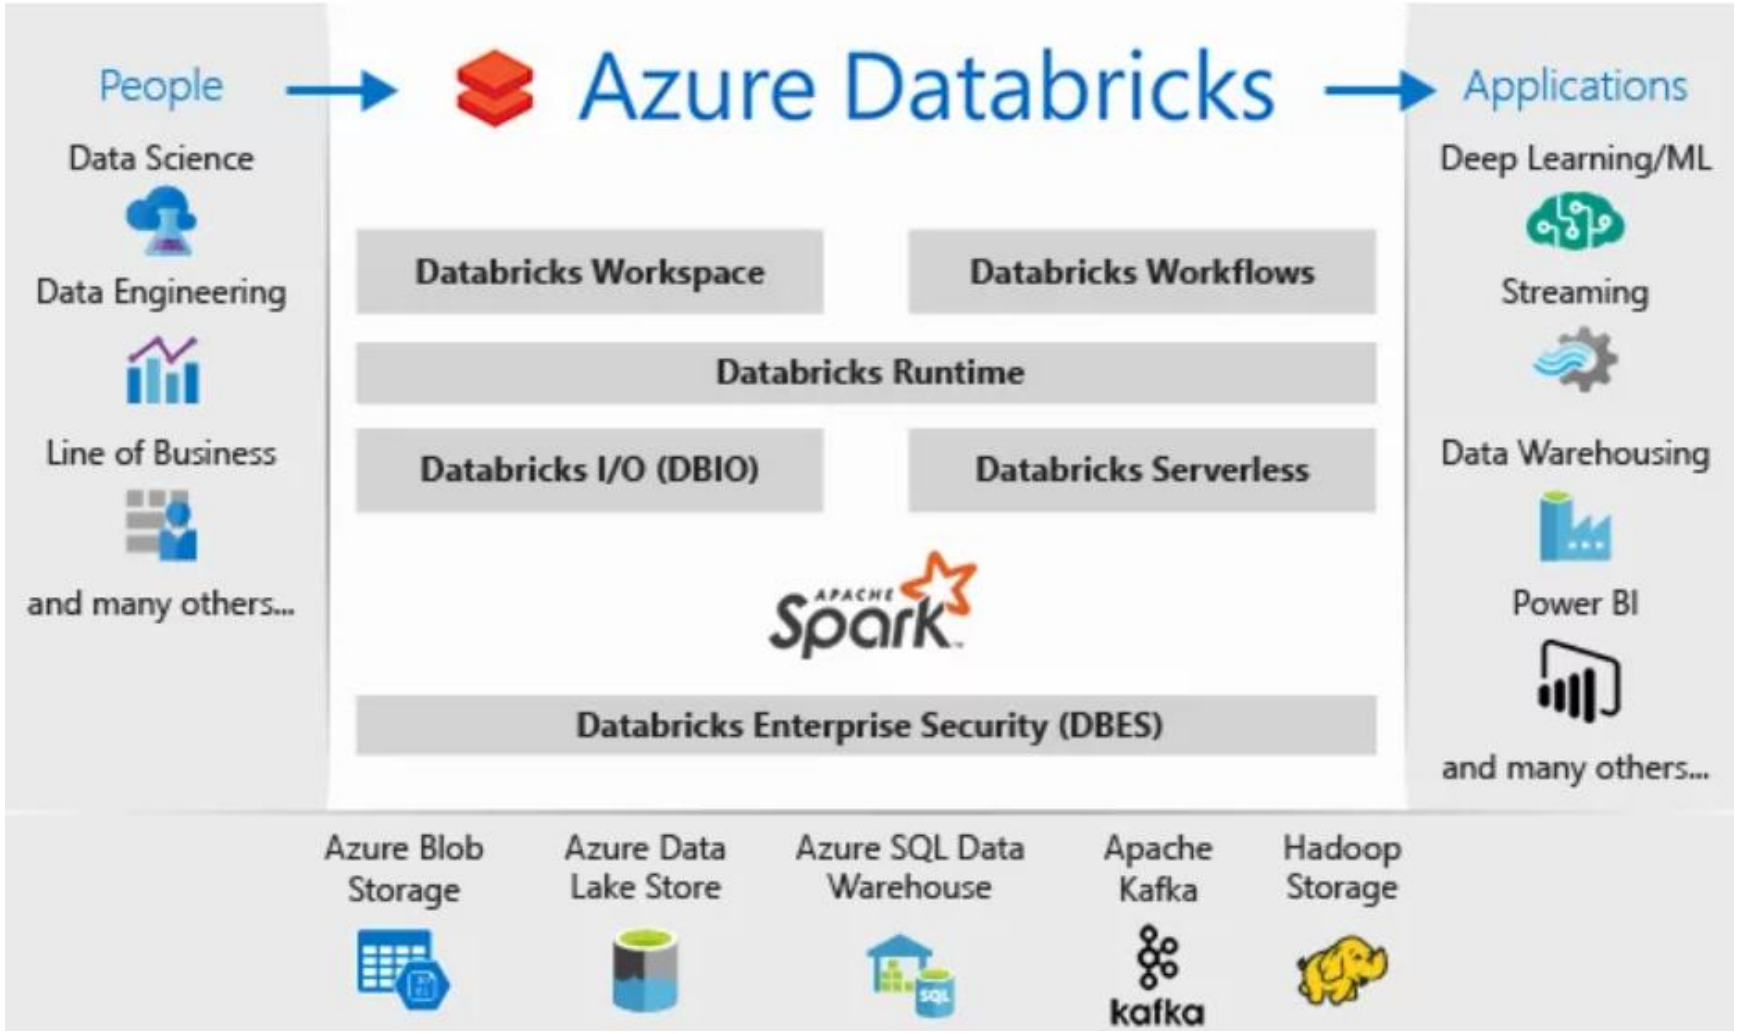
Databricks es el nombre de la plataforma analítica de datos basada en Apache Spark desarrollada por la compañía con el mismo nombre. La empresa se fundó en 2013 con los creadores y los desarrolladores principales de Spark. Permite hacer analítica Big Data e inteligencia artificial con Spark de una forma sencilla y colaborativa.

Esta plataforma está disponible como servicio cloud en Microsoft Azure y Amazon Web Services (AWS).



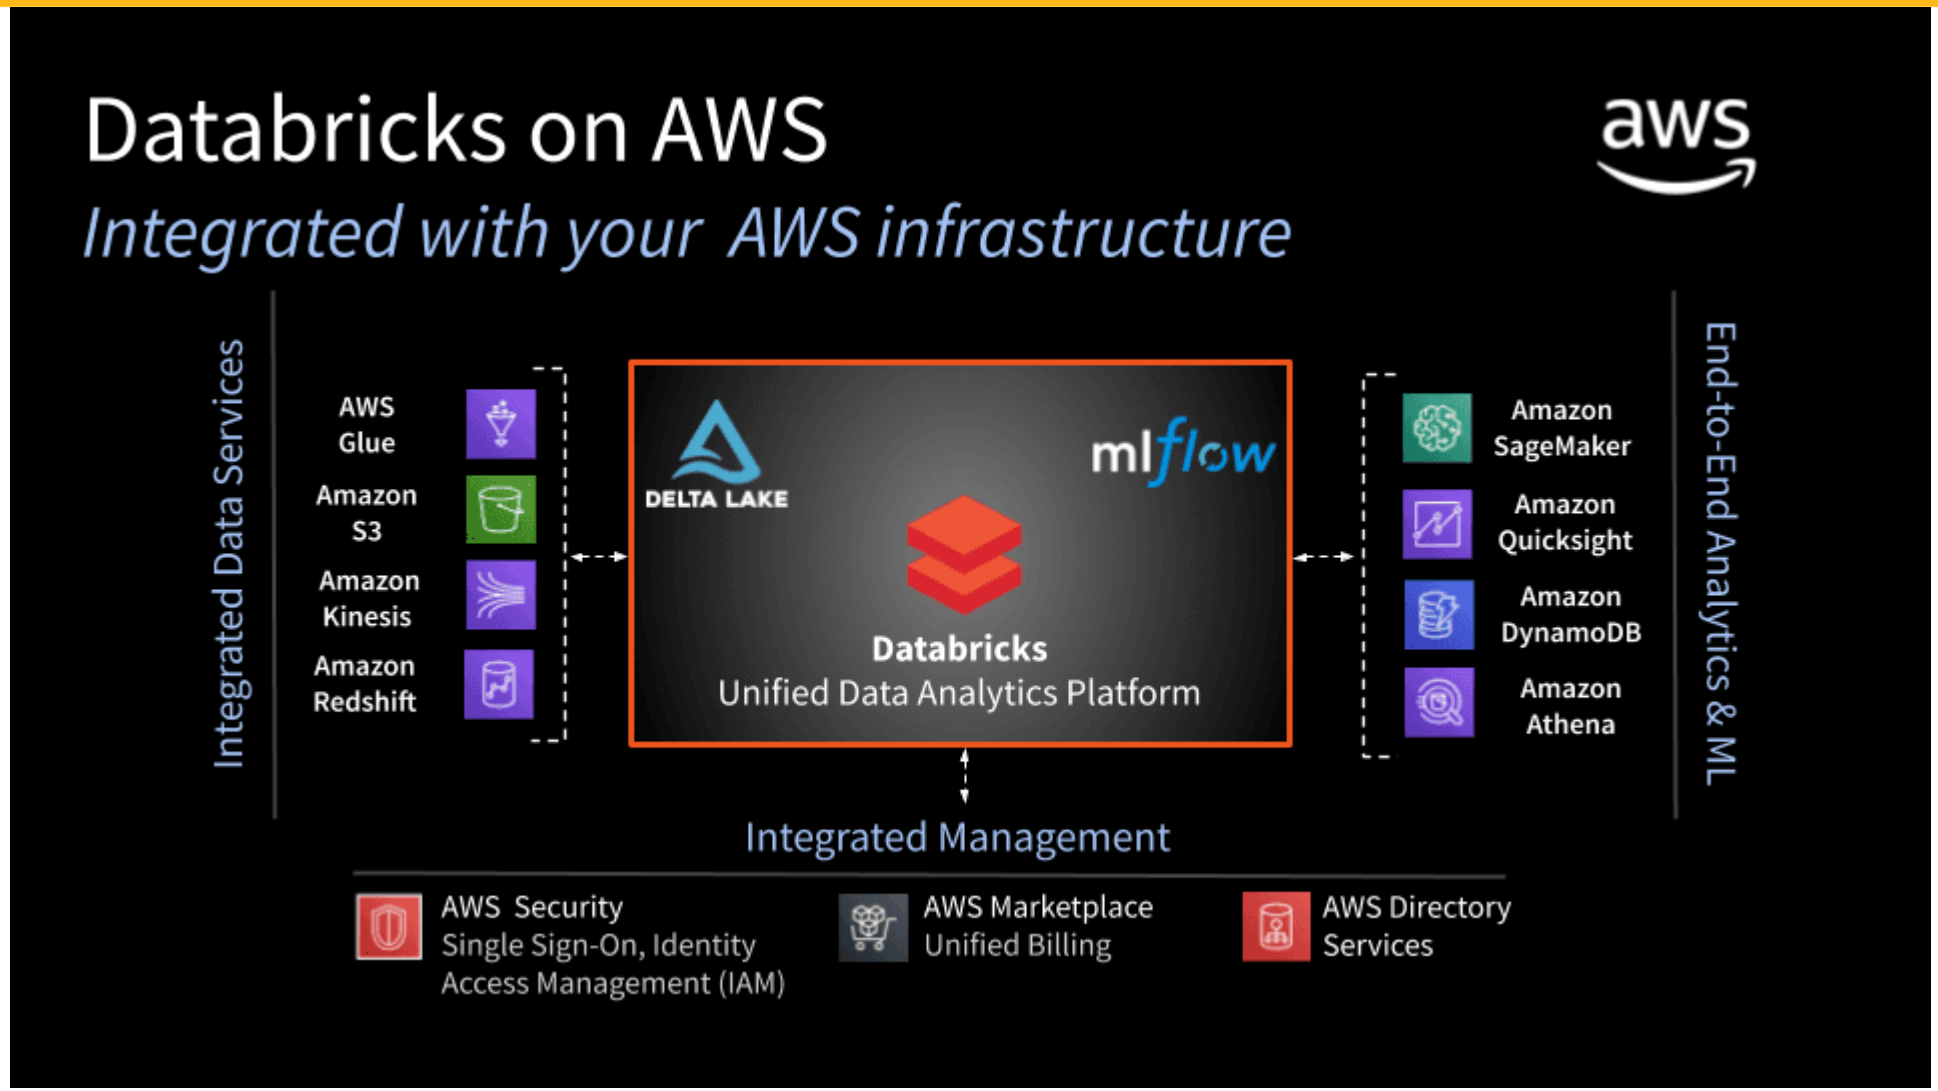
https://aprenderbigdata.com/databricks/

DATABRICKS



https://aprenderbigdata.com/databricks/

DATABRICKS



https://aprenderbigdata.com/databricks/

¿Preguntas o comentarios?



CONCLUSIONES

Apache Spark es un framework open source que permite **procesar** grandes volúmenes de información de forma óptima, debido al trabajo que realiza en memoria.

Databricks consiste en una plataforma interactiva y colaborativa en la nube basada Apache Spark que se emplea para el proceso, análisis y transformación de datos, facilitando el diseño de modelos de aprendizaje automático complejos (Machine Learning).

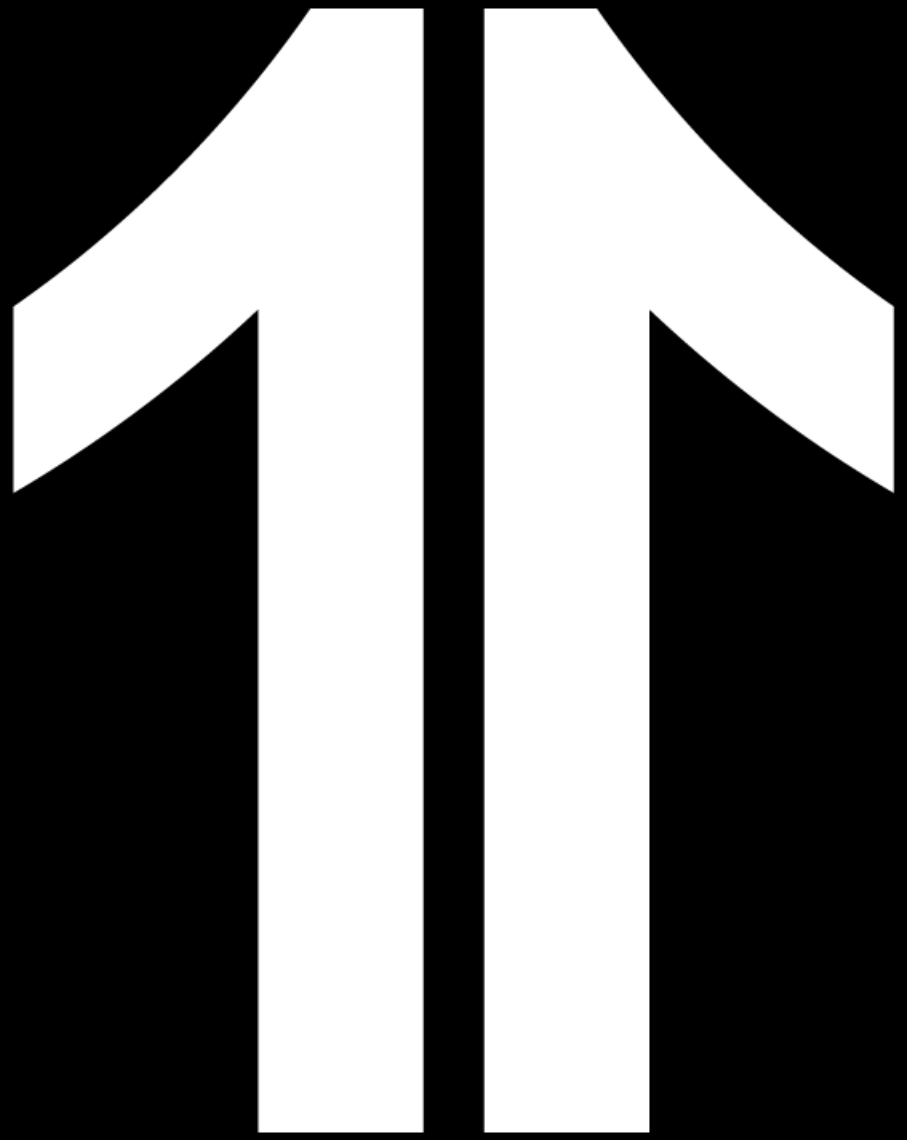


REFERENCIAS BIBLIOGRÁFICAS

Qué es spark?

https://learn.microsoft.com/es-es/dotnet/spark/what-is-spark

Databricks
https://aprenderbigdata.com/databricks/



GRACIAS


UPN
UNIVERSIDAD
PRIVADA
DEL NORTE